UNIVERZITET U BEOGRADU MATEMATIČKI FAKULTET



Vladimir Vuksanović

UNAPREĐENJE INFRASTRUKTURE LLVM ČUVANJEM ORIGINALNE LOKACIJE PRI DEBAGOVANJU IZDVOJENOG KODA

master rad

	JJOŠEVIĆ JANIČIĆ, va Beogradu, Matematič	_
Članovi koi	nisije:	
_	IĆ, redovan profesor Beogradu, Matematič	ki fakultet
dr Mirko SPA Univerzitet u	SIĆ, docent Beogradu, Matematič	ki fakultet

Naslov master rada: Unapređenje infrastrukture LLVM čuvanjem originalne lokacije pri debagovanju izdvojenog koda

Rezime: Skoro sav moderan softver napisan je u višem programskom jeziku što znači da je potrebno kompajlirati ga do izvršnog koda kako bi mogao da se koristi. Prilikom kompilacije taj program se optimizuje radi postizanja boljih performansi u vidu vremena izvršavanja ili memorijskog zauzeća. Dok su optimizacije pogodne za normalno izvršavanje, problem može da nastane prilikom pokretanja optimizovanog programa pomoću debagera. Debager se oslanja na informacije za debagovanje koje kompajler generiše pored mašinskog koda, ali te informacije je teško održati što se više krajnji kod razlikuje od početnog. Ovaj problem se susreće prilikom optimizacije izdvajanje koda u kompajleru LLVM. Izdvajanje koda je memorijska optimizacija koja pronalazi segmente koda koji se ponavljaju i premešta ih u jednu funkciju pritom zamenjujući sve segmente pozivom nove funkcije. Posledica manje količine koda je što nema dovoljno mesta za zapis lokacija u izvornom kodu koje čine bitan deo informacija za debagovanje. Ovaj rad ima cilj da popravi to ponašanje i sačuva što je više moguće originalnih lokacija izdvojenog koda i da ih upotrebi za poboljšanje procesa debagovanja. Poboljšanja debagera obuhvataju podršku za ispisivanje lokacija izdvojenih instrukcija, koračanje po njima i postavljanje tačaka prekida na njih. Rešenje je implementirano kao nadogradnja alata iz infrastrukture LLVM, ali se ideja može primeniti na druge kompajlere i debagere.

Ključne reči: izdvajanje koda, kompajler, debager, informacije za debagovanje, projekat LLVM, kompajler LLVM, debager LLDB

Sadržaj

1	Uvo	od	1				
2	Kompajleri						
	2.1	Struktura modernih kompajlera	4				
	2.2	Kompajlerske optimizacije	4				
	2.3	Kompajler LLVM	6				
3	Deb	pageri	14				
	3.1	Informacije za debagovanje	16				
	3.2	Format DWARF	17				
	3.3	Debager LLDB	20				
4	Opt	timizacija izdvajanjem koda	23				
	4.1	Implementacija u kompajleru LLVM	25				
	4.2	Izdvajanje koda i debag lokacije	29				
5	Imp	olementacija rešenja	32				
	5.1	Implementacija u kompajleru	32				
	5.2	Implementacija u debageru	41				
6	Rez	zultati	49				
7	Zaključak						
Bi	iblios	grafija	55				

Glava 1

Uvod

Viši programski jezici (eng. high-level programming languages) su drastično promenili način na koji se pravi softver. Programeri više ne moraju da budu detaljno upoznati sa detaljima hardvera već pišu programe nezavisno od arhitekture. Apstrakcija koju nude viši jezici omogućava programerima da razmišljaju na prirodniji način, koristeći napredne konstrukte tog jezika. Kako računari ne mogu direktno da izvrše kôd na višem jeziku, potrebno je prevesti ga u mašinski kôd za ciljnu arhitekturu. Za taj posao zadužen je kompajler. Pored glavnog zadatka da prevede program napisan na višem jeziku u sematički ekvivalentan program za neku mašinu, sporedni zadatak kompajlera je da usput transformiše taj program tako da ima bolje performanse.

Napisan i preveden program može da ima propuste u svojoj implementaciji. Zbog toga, bitan deo razvoja softvera je rešavanje grešaka u napisanom programu. Jedan od najtežih delova tog procesa je pronaći deo koda koji izaziva grešku. Taj korak je znatno olakšan korišćenjem specijalizovanih alata, debagera. Oni uz pomoć podrške operativnog sistema preuzimaju kontrolu nad programom u kome se traži greška što im omogućava da upravljaju njegovim izvršavanjem i čitaju svu njegovu memoriju. To omogućava interaktivno izvršavanje programa, pregled vrednosti promenljivih i izraza kao i brojne naprednije mogućnosti. Za ugodan rad debagera potrebna je pomoć od strane kompajlera da sačuva podatke o izvornom kodu prilikom kompilacije nekog programa. Ti podaci se nazivaju informacije za debagovanje. Značajan deo tih informacija čine lokacije za debagovanje koje povezuju delove izvršnog fajla sa odgovarajućum delovima izvornog koda na osnovu kojih su generisani. Prevođenjem programa sa optimizacijama predstavlja problem održavanju informacija za debagovanje. Što se program više udaljava od izvornog koda postaje teže, ako ne i

nemoguće, ažurirati informacije za debagovanje tako da i dalje opisuju izvorni kôd.

Prethodni problem utiče na implementaciju optimizacije izdvajanja koda u kompajleru LLVM. Izdvajanje koda je kompajlerska optimizacija čiji cilj je smanjenje količine memorije potrebne za program tako što više puta ponovljen kôd pomera u zasebnu funkciju i duplikati brišu. Smanjenje ukupnog broja instrukcija u programu onemogućava skladištenje lokacija na redovan način zato što bi jednoj instrukciji odgovaralo više različitih lokacija, a to trenutno nije podržano. Posledice nedostatka lokacija prilikom debagovanja je što neke osnovne operacije mogu imati neočekivane rezultate. Između ostalog, koračanje po programu potpuno preskače instrukcije bez lokacije i nije moguće postaviti tačku prekida na iste. U ovoj tezi biće predloženo rešenje za čuvanje originalnih lokacija u izvornom kodu za instrukcije izmeštene optimizacijom izdvajanja koda. Rešenje uključuje skladištenje lokacija na drugo mesto u programu gde će u vreme izvršavanja biti moguće odrediti korektnu lokaciju. Na osnovu tih lokacija biće poboljšan rad debagera na izvdvojenom kodu. Rešenje je implementirano kao nadogradnja kompajlera LLVM i debagera LLDB.

Ostatak rada je organizovan na sledeći način. Poglavlje 2 opisuje kompajlere i njihovu strukturu, sa posebnom pažnjom posvećenom optimizacijama izvornog koda koje kompajleri izvršavaju. Takođe su detaljno opisane faze kompilacije u okviru kompajlera LLVM za koje će biti implementirano rešenje. U poglavlju 3 se govori o rešavanju grešaka u softveru pomoću debagera, informacijama za debagovanje koje su neophodne za to i formatu DWARF za predstavljanje tih informacija. Na kraju poglavlja opisan je debager LLDB kao i glavni delovi njegove implementacije. Poglavlje 4 uvodi optimizaciju izdvajanja koda, opisuje njene implementacije u kompajleru LLVM i predstavlja problem koji je tema ovog rada. Implementacija rešenja podeljena je na dva dela u okviru poglavlja 5. Prvi deo se bavi implementacijom na strani kompajlera gde je cilj očuvati informacije za debagovanje, a drugi deo implementacijom u debageru gde se sačuvane informacije koriste za poboljšanje podrške za izdvojen kôd. Rezultati implementiranih poboljšanja, kao i testovi ispravnosti predstavljeni su u poglavlju 6. Na kraju, u poglavlju 7 iznet je zaključak rada.

Glava 2

Kompajleri

Računari izvršavaju programe koji su u obliku mašinskog koda. Kako je nepogodno za ljude da čitaju i pišu takav kôd bilo je potrebno da se on na neki način apstrahuje. Prva apstrakcija nastala je u vidu asemblerskog koda. On je uveo mnemonike za mašinske instrukcije što je znatno poboljšalo čitljivost koda. Kako računar još uvek razumeju samo mašinski kôd, nastali su posebni alati, asembleri, koji vrše jednostavne zamene mnemonika i operanada sa odgovarajućim mašinskim kodom. Programiranje direktno asemblerskim jezikom je veoma izazovan posao koji zahteva precizno poznavanje računara za koji se prevodi program. Potreba za pisanjem kompleksnijeg softvera dovela je do nastanka viših programskih jezika. Ti jezici omogućavaju programerima da koriste složenije koncepte i već poznate algoritme i strukture podataka bez potrebe da sami implementiraju sve iz početka. Prevođenje viših jezika je zantno izazovnije od jednostavne tekstualne zamene koju rade asembleri. Alati za prevođenje sa koda sa višeg programskog jezika nazivaju se kompajleri.

Zadaci kompajlera su višestruki. Glavni zadatak je da prevede izvorni kôd u sematički ekvivalentan mašinski kôd. Pored toga, proces kompilacije treba da se brzo izvršava kako bi veliki programi mogli da se prevedu u razumnoj količini vremena. Uz to, poželjno svojstvo je da i konačni program bude što efikasniji. Na kraju, kompajler treba da prilikom prevođenja, ukoliko mu je zatraženo, sačuva informacije o izvornom kodu i poveže delove konačnog programa sa odgovarajućim delovima tog koda. Poslednja dva zadatka nisu neophodna, ali ih svaki dobar kompajler radi.

U nastavku poglavlja će biti prvo opisana opšta struktura modernih kompajlera i zašto se ona koristi. Zatim će biti reci o optimizacijama koje kompajler vrši nad izvornim kodom uz nekoliko primera. Poglavlje će biti završeno predstavljanjem


kompajlera LLVM sa više detalja o implementaciji svakog od osnovnih delova njegove strukture.

2.1 Struktura modernih kompajlera

Kompajleri su veoma kompleksni softverski sistemi. Kako postoje već dugo vremena i čine ključne alate za razvoj softvera, kompajleri su tema brojnih istraživanja. Kao rezulat tih istraživanja dobijeno je dosta informacija o dobrim načinima za struktuiranje i implementaciju kompajlera. Moderni kompajleri se obično sastoje iz tri dela [2]:

- Prednji deo Analizara i prevodi izvorni kôd na neku internu reprezentaciju.
 Pritom vrši leksičku, sintaksičku i semantičku analizu nad kodom. Ukoliko korisnički kôd nije ispravan, kompilacija se završava ovde.
- Optimizator Optimizuje internu reprezentaciju kako bi se postigao neki cilj.
 Može da radi u jednom ili više prolaza.
- Zadnji deo Prevodi validnu internu reprezentaciju do programa koji može da se izvrši na ciljnoj mašini.

Samo prednji i zadnji deo su potrebni za generisanje mašinskog koda. Optimizator je opcioni deo nastao iz potrebe da dobijeni kôd bude performantan. Svaki dobar kompajler ga ipak sadrži, i on je možda čak najveći deo kompajlera. Odnos ovih delova je prikazan na slici 2.1. U svakom trenutku program je enkodiran u neku vrstu interne reprezentacije. Ta reprezentacija postaje sve bliža mašinskom kodu u svakom koraku. Ovakva struktura omogućava lako dodavanje podrške bilo za druge programske jezike i, bitnije, za podržavanje novih arhitektura.



2.2 Kompajlerske optimizacije

Kompajleri osim prevođenja izvornog koda do mašinskih instrukcija takođe mogu da ga modifikuju za bolje performanse sve dok se optimizovani kôd isto ponaša

kao originalni. Performanse mogu da se odnose na vreme izvršavanja programa, memorijski prostor potreban prilikom izvršavanja ili memorijski prostor potreban za skladištenje izvršnog fajla. U zavisnosti od faze kompilacije u kojoj se rade, optimizacije mogu biti nezavisne ili zavisne od ciljne arhitekture. Nezavisne optimizacije rade za sve ciljne arhitekture i oslanjaju se na smanjivanje ukupnog broja operacija koje treba izvršiti. Zavisne optimizacije iskorišćavaju detalje arhitekture kako bi podigli performanse. To se ogleda u korišćenju instrukcija koje rade više operacija u isto vreme ili instrukcija koje rade brže od alternativnih. Čest primer na arhitekturi x86_64 je zamena instrukcije mov eax, 0 sa instrukcijom xor eax, eax.

Primeri nekih bitnih optimizacija su:

- Savijanje konstanti (eng. constant folding) programeri često ostavljaju konstantne matematičke izraze bez promenljivih u kodu zato što je čitljivije nego da izračujaju vrednost. Kako izraz ne sadrži promenljive, nema razlog da se on evaluira za vreme izvršavanja svaki put već se to radi u vreme kompilacije.
- Eliminacija mrtvog koda (eng. dead code elimination) statičkom analizom je moguće u specijalnim slučajevima utvrditi da se neki deo programa nikada neće izvrsiti. Brisanjem tog koda štedi se memorija, ubrzava proces kompilacije i može da se ubrza vreme izvršavanja zbog bolje organizacije keš memorije.
- Globalna numeracija vrednosti (eng. global value numbering) neki izrazi ili delovi izraza se mogu javiti na više mesta u kratkom rasponu. Ukoliko su izračunati jednom, nije potrebno računati ih ponovo već je moguće obezbediti da prethodni rezultat ostane dostupan u memoriji dok nije ponovo potreban.
- Razmotavanje petlji (eng. loop unrolling) izvršavanje petlji sa kratkim telom dovodi do velikog broja skokova u maloj količini vremena. Skokovi su skupa instrukcija i njihovim smanjenjem mogu znatno da se povećaju performanse programa. Razmotavanje se radi tako što se telo petlje ponovi više puta u jednoj iteraciji i broj iteracija se isti broj puta smanji. Ovo je moguće samo u posebnim situacijama kada kompajler ima dovoljno informacija o načinu izvršavanja petlje.

Postoji nekoliko nivoa optimizacije koji se mogu podesiti u prilikom poziva kompajlera. Izbor nivoa određuje koje optimizacije treba da se izvrše a koje ne. Način

odabira i nivoi optimizacije su drugačiji na različitim kompajlerima. Na kompajlerima gcc i clang korisnik moze da izabere koji nivo tako što prosledi zastavicu -0 iza koje se javlja neki od karaktera 0, 1, 2, 3 ili s¹. 00 je podrazumevani nivo ukoliko nijedan drugi nije specificiran i označava da se kôd uopšte ne optimizuje. Ovaj režim se koristi za pravljenje debag verzija programa. Više reči o tome će biti u poglavlju 3.1. 01 i 02 redom uključuju sve veći broj optimizacija podrazumevano da one drastično ne povaćavaju memorijsku složenost programa. 03 ja najveći nivo optimizacije vremena izvršavanja. On podrazumeva sve što se koristi u 02, ali uključuje i optimizacije koje mogu da znatno povećaju memorijsko zauzeće programa. Isporučene verzije programa se često kompajliraju na ovaj način. Sa druge strane 0s nivo takođe podrazumeva sve optimizacije iz 02 ali dodatno i optimizacije koje smanjuju memorijsko zauzeće na uštrb vremena izvršavanja. Ovaj nivo se koristi za uređaje sa ugrađenim računarom (eng. embedded devices) koji imaju malu količinu memorije.

2.3 Kompajler LLVM


Projekat LLVM započet je 2000. godine na Univerzitetu Ilinois od strane Krisa Latnera. Ubrzo se projektu pridružio i njegov mentor Vikram Adve. Cilj projekta je bio proučavanje tehnika kompajliranja u SSA obliku (eng. Static Single Assignment) koja podržava statičku i dinamičku kompilaciju proizvoljnih programskih jezika. Inicijalno, naziv LLVM je bio akronim za "virutelna mašina niskog nivoa" (eng. Low Level Virtual Machine). Od tada akronim se više ne koristi, ali je ime ostalo nepromenjeno. Danas, projekat pokriva veliki broj biblioteka i alata za programiranje niskog nivoa [6]. Svaki deo projekta je dizajniran kao biblioteka tako da se može ponovo upotrebiti za implementiranje drugih alata. Celokupan izvorni kôd je javno dostupan na servisu GitHub. Prednost pristupu otvorenog koda je da svako ko želi da poboljša kôd ili ispravi neku grešku može to da učini. Velika zajednica se formirala oko projekta što je znatno doprinelo njegovoj popularnosti. Mnoge firme koriste svoje verzije kompajlera LLVM bilo za podršku neke arhitekture ili kao osnovu za novi programski jezik.

Glavnu komponentu projekta LLVM čini kolekcija biblioteka u okviru istoimenog potprojekta. One implementiraju optimizator i zadnji deo kompajlera i koriste se od strane većine ostalih alata. Drugi bitan potprojekat je clang. On implementira

¹Ovo nije potpuna lista. Postoje nivoi koji nisu navedeni.

prednji deo kompajlera za jezike C, C++ i Objective-C. LLVM implementira i svoj debager koji se zove LLDB. Više reči o njemu će biti u glavi 3.3. Postoji još veliki broj biblioteka i pomoćnih alata koji nisu pomenuti zato što nisu predmet ovog rada.

Kompajler LLVM je relativno nov u odnosu na druge popularne C++ kompajlere i prati moderniji dizajn. Za razliku od kompajlera GCC, koji je napisan u jeziku C i ima monolitnu strukturu, LLVM uživa u pogodnostima proširenja koje nudi jezik C++ pritom koristeći modularnu arhitekturu. Dok je najveći deo projekta napisan u programskom jeziku C++, postoji interfejs za povezivanje sa jezicima C i Python. Implementacija kompajlera LLVM prati opštu strukturu kompajlera prikazanu u poglavlju 2.1 [1]. Korake kompilacije izvršavaju različiti alati. Odnos različitih reprezentacija koje program ima u toku kompilacije i alata koji konvertuju iz jedne reprezantacije u drugu je prikazan na slici 2.2.



Slika 2.2:

U nastavku će biti opisani redom prednji, srednji i zadnji deo LLVM kompajlera sa fokusom na poslednja dva kako su oni bitniji za ovaj rad.

Prednji deo

Projekat LLVM sadrži vise različitih prednjih delova kompajlera. Druge organizacije i firme takođe proizvode i održavaju prednje delove kompajlera LLVM za svoje jezike. Iz tog razloga, LLVM podržava veliki broj programskih jezika koji uključuju C, C++, Objectve-C, Fortran, Haskell, Swift i druge. Prednji deo za programske jezike C i C++ koji su fokus ovog rada naziva se clang. Pre nastavka dalje, potrebno je razjasniti terminologiju. Naime, postoji nekoliko značenja termina clang. Može se smatrati da je to prednji deo kompajlera, kao u skladu sa prethodnim korišćenjem izraza, zatim se može podrazumevati da je to alat koji upravlja celim procesom kompilacije ili može da bude biblioteka koja implementira funkcionalnost prednjeg dela kompajlera. Nadalje se podrazumeva prva interpretacija.

Funkcija ovog dela kompajlera je da izvorni kôd, u ovom slučaju napisan u jezicima C ili C++ prevede u LLVM međureprezentaciju. Usput se izvršavaju sve provere ispravnosti izvornog koda i prikazuju se greške i upozorenja korisniku. Program se detaljno analizira iz nekoliko koraka i pritom dolazi do transformacija izvornog koda.

Prvo se prepoznaju osnovne jedinice gramatike programskog jezika, odnosno lekseme. Lekseme se pretvaraju u različite tipove tokena u zavisnosti od toga šta označavaju. Na primer za ključne reči programskog jezika postoje različite vrste tokena, dok svi identifikatori imaju isti tip tokena. Tokeni osim tipa imaju i informacije o opsegu koji zauzimaju u izvornom kodu pomoću kog se može pristupiti njihovom tekstu. Nad nizom tokena se zatim radi sintaksna analiza ili parsiranje u skladu sa pravilima gramatike jezika. Ta pravila se zadaju korišćenjem kontekstno-slobodne gramatike. Primenom pravila gradi se sintaksno stablo gde unutrašnji čvorovi predstavljaju operacije a njihova deca su argumenti. Parsiranje utvrđuje da li program ima ispravnu strukturu ali ne proverava da li taj program ima smisao. To je zadatak semantičke analize. Program može da ima dobru strukturu, ali da nema validno značenje. Prolaskom kroz sintaksno stablo se prikupljaju informacije o funkcijama, promenljivima i drugim objektima i smeštaju se u tabelu simbola. Korišćenjem te tabele proverava se ispravnost sintaksnog stabla. Primer provere koja se vrši na ovom nivou je da li je korišćena promenljiva deklarisana pre toga. Rezultat svih ovih analiza je program u obliku apstraktnog sintaksnog stabla (eng. Abstract Syntax Tree, AST).

U biblioteci clang parsiranje i semantička analiza su usko povezani, a lekser se poziva po potrebi od strane parsera [16]. Bitan deo leksera čini pretprocesor koji izvšava direktive poput #include i #define. Prilikom primene pravila gramatike parser zahteva tokene od leksera i delegira posao kreiranja sintaksnog stabla semantičkom analizatoru. Ukoliko se pronađe greška u bilo kojoj analizi, program se ne moze kompajlirati i poruka o razlogu se vraća korisniku. U suprotnom, obilaskom apstraktnog sintaksnog stabla generiše se LLVM međukod. Komanda za prevođenje programa do LLVM međukoda prikazana je u listingu 2.3.

clang -S -emit-llvm -o output.ll input.c

Slika 2.3:

Ukoliko se program uspešno prevede do međukoda, onda je izvorni kôd validan za jezik u kome je napisan. Još uvek je moguće da dođe do greške prilikom povezivanja zbog ne postojanja definicija nekih funkcija, ali će kompilacija do asemblerskog ili objektnog koda biti uspešna. Naravno, činjenica da se program kompajlira ne znači da on radi ono što je programer zamislio niti da će se program uvek uspešno završiti.

Optimizator

Prednji deo prevodi izvorni kôd u LLVM mašinski nezavisan međukod. U terminologiji se koristi skraćenica IR (eng. Intermediate Representation). Izbor reprezentacije međukoda je veoma bitan kada kompajler treba da podrži i više programskih jezika i više ciljnih arhitektura. On treba da je na dovoljno visokom nivou da ne zavisi od arhitekture i u isto vreme na dovoljno niskom nivou da ne zavisi od prgramskog jezika [15]. LLVM međukod je u SSA obliku. To znači da je svakoj promenljivoj vrednost dodeljena samo jednom i da svakoj upotrebi promenljive prethodi njena definicija. Ovaj oblik je izabran zato što je pogodan za izvršavanje optimizacija.

U listingu 2.4 je dat primer LLVM međukoda za sitan program. Svaki fajl sa LLVM međukodom čuva informacije o jednom modulu. Na početku fajla se nalazi ime fajla u kojem se nalazi izvorni kôd, informacije o načinu zapisa podataka i naziv ciljne arhitekture. U nastavku su globalne promenljive i funkcije. One se prepoznaju po tome što im imena imaju prefiks '@'. Svaka funkcija se sastoji od niza osnovnih blokova, a svaki blok od niza instrukcija. Osnovni blok je jedinica čije instrukcije se uvek linearno izvršavaju. Ako se uđe u osnovni blok on će se uvek izvršiti do kraja. Dakle instrukcije grananja smeju i moraju da se pojave na kraju bloka. Granice osnovnih blokova su ozačene kao labele u jeziku C. Takođe, početak funkcije započinje prvi osnovni blok. U okviru funkcije lokalne promenljive su zamenjene virtuelnim registrima. Identifikatori virtuelnih registara pocinju karakterom '%'. Zbog SSA oblika, svakom od njih se može dodeliti vrednost tačno jednom. Smatra se da tih registara ima neograničen broj. Instrukcije se sastoje od naziva (alloca, call, icmp, ...), tipa (i32, float, label, ...) i operanada. Ukoliko isntrukcija vraća vrednost, on se smešta u novi virtuelni registar. Dodatne informacije o instrukcijama i globalnim objektima se čuvaju u vidu metapodataka. Oni se mogu prepoznati po tome sto počinju karakterom '!'. Između ostalog, oni se koriste za informacije za debagovanje. Vise reči o primeni metapodataka će biti u glavi 3.1. Kompletan pregled jezika LLVM IR dostupan je na internetu [7].

Optimizacije su implementirane u vidu prolaza (eng. *pass*) koji obrađuju modul, funkciju ili petlju. Prolazi nasleđuju apstraktnu klasu PassInfoMixin i implementiraju funkciju run sa argumentima za odgovarajuću jedinicu obrade. Prolazi se dele

```
; ModuleID = 'helloworld.c'
   source_filename = "helloworld.c"
   target datalayout =
    → "e-m:e-p270:32:32-p271:32:32-p272:64:64-i64:64-f80:128-n8:16:32:64-S128"
   target triple = "x86_64-redhat-linux-gnu"
4
5
   0.str = private unnamed_addr constant [3 x i8] c"%d\00", align 1
6
   @.str.1 = private unnamed_addr constant [14 x i8] c"hello, world!\00", align 1
7
8
   ; Function Attrs: noinline nounwind optnone uwtable
10
   define dso_local i32 @main() #0 {
      %1 = alloca i32, align 4
11
      %2 = alloca i32, align 4
12
      store i32 0, ptr %1, align 4
13
      %3 = call i32 (ptr, ...) @__isoc99_scanf(ptr noundef @.str, ptr noundef %2)
14
      %4 = load i32, ptr %2, align 4
15
      %5 = srem i32 %4, 2
16
      \%6 = icmp eq i32 \%5, 0
17
      br i1 %6, label %7, label %9
18
19
                                                        ; preds = %0
20
      %8 = call i32 (ptr, ...) @printf(ptr noundef @.str.1)
21
     br label %9
22
23
   9:
                                                        ; preds = %7, %0
24
25
     ret i32 0
26
   }
27
   declare dso_local i32 @__isoc99_scanf(ptr noundef, ...) #1
28
29
   declare dso_local i32 @printf(ptr noundef, ...) #1
30
31
32
33
    !llvm.module.flags = !{!0, !1, !2}
34
35
    !llvm.ident = !{!3}
36
37
    !0 = !{i32 1, !"wchar_size", i32 4}
   !1 = !{i32 7, !"uwtable", i32 2}
   !2 = !{i32 7, !"frame-pointer", i32 2}
   !3 = !{!"clang version 15.0.7 (Fedora 15.0.7-2.fc37)"}
```

Slika 2.4:

na analize i transformacije. Analize prikupljaju podatke dok transformacije koriste te podatke kako bi izmenili kôd. Transformacija zahteva različite vrste analiza i može da ih poništi ako više ne važe posle promene koda. Optimizacije se primenjuju na program inkrementalno. Program dobijen kao izlaz iz jedne optimizacije postaje ulaz sledećoj optimizaciji. Dakle konačan program zavisi od redosleda izvršavanja

optimizacija. Loš redosled može da rezultuje znatno lošijim performansama izvršnog fajla. Svaki nivo optimizacije propisuje koje optimizacije treba da budu primenjene i kojim redosledom.

Za primenu optimizacija na LLVM IR fajlu se koristi alat opt. On prima imena optimizacija koje treba da pokrene i fajl sa ispravnim IR programom koji da optimizuje. Takođe moguće je pokretanje korisnički napisanih prolaza učitanih kao dinamičke biblioteke [13]. Primer korišćenja alata je prikazan u listingu 2.5.

opt -passes="mem2reg,instnamer" -o input_opt.ll input.ll

Slika 2.5:

Zadnji deo

Pre generisanja mašinskog koda, postoji jos jedna, mašinski zavisna, interna reprezentacija. U terminologija projekta LLVM, ona se naziva MIR (eng. *Machine Intermediate Representation*). Ona je dosta bliža ciljnoj arhitekturi i sastoji se od instrukcija te arhitekture. MIR kôd se zapisuje u formatu YAML. Tela funckija su parsirana kao obična niska. Struktura instrukcija je slična kao za IR kôd. Najveće razlike su u tome što su intrukcije vezane za konkretnu arhitekturu i virtuelni registri su zamenjeni pravim registrima. Kompletan pregled jezika dostupan je u okviru dokumentacije projekta LLVM [8].

Veliki i kompleksan korak u prevođenju koda je spuštanje sa mašinski nezavisne na mašinski zavisnu reprezentaciju. Taj korak se naziva izbor instrukcija (eng. *Instruction Selection*). Postoje tri implementacije izbora instrukcija:

- SelectionDAG Podrazumevana implementacija izbora instrukcija na većini arhitektura.
- GlobalIsel Nova implementacija izbora instrukcija sa modularnim dizajnom, poboljšanim performansama i mogućnosti da optimizuje veći deo kôda.
 Trenutno nije završena implementacija, ali se planira da u budućnosti zameni SelectionDAG.
- FastIsel Pristup izboru instrukcija koji radi veoma brzo, ali generiše neoptimizovan kôd. Ne podržava spuštanje svih ilegalnih instrukcija i u tim situacijama se oslanja na SelectionDAG.

Ovaj rad se fokusira na implementaciju SelectionDAG zbog svoje stabilnosti i zato što je podrazumevana za arhitekturu x86_64.

SelectionDAG je dobio ime po načinu reprezentacije koda za vreme izbora instrukcija. Naime, odgovarajuća klasa se takođe zove SelectionDAG. Osnovni blokovi programa su predstavljeni usmerenim acikličkim grafovima (eng. Directed Acyclic Graphs). Čvorovi tog grafa su instrukcije koje imaju tip SDNode, a grane su različite zavisnosti koje postoje između instrukcija. Postoje dva posebna čvora: ulazni čvor i koren. Ulazni čvor obeležava početak osnovnog bloka i služi samo za postavljanje veza. Sa druge strane, koren označava kraj bloka. Na kraju obrade je vezan za poslednju instrukciju osnovnog bloka. Kontrukcija se radi prolaskom kroz LLVM međukod pomoću klase SelectionDAGBuilder koja implementira obrazac "posetilac". Za svaku instrukciju se kreira čvor na osnovu njenog koda. Konstrukcija čvora se radi direktno u klasi SelectionDAG. Veze se kreiraju kada neki čvor koristi izlaznu vrednost drugog čvora. Tip te vrednosti određuje tip veze.

Prethodno konstruisan graf nije pogodan za spuštanje instrukcija i nad njim se vrše dodatne transformacije. On se dodatno optimizuje zamenom grupe čvorova sa jednostavnijim grupama uz pomoć algoritama za uparivanje stabala. Te optimizacije mogu da budu i mašinski nezavisne i zavisne. Graf takođe može da sadrži nepodržane tipove i operacije za ciljnu arhitekturu. Njih je potrebno zameniti odgovarajućim podržanim varijantama. Ove transformacije se zovu legalizacija tipova i operacija. Način legalizacije zavisi od arhitekture i implementiran je u odgovarajućim TargetLowering klasama. Prolazi optimizacije i legalizacije se rade nekoliko puta u određenom redosledu i rezultuju grafom spremnim za spuštanje instrukcija.

Proces spuštanja instrukcija kada su sve potrebne pripreme izvršene je prilično jednostavan. Kao i prilikom optimizacija, algoritam se zasniva na uparivanju čvorova. Čvorovi svake SelectionDAG strukture traže svoj pandan za ciljnu arhitekturu. Arhitektura definiše ta uparivanja u svojoj podklasi klase SelectionDAGISel. Ona definiše funkciju Select koja prima objekat tipa SDNode i vraća čvor sa mašinski zavisnim kodom operacije. U ovom koraku se ne zamenjuju baš svi čvorovi već neki prolaze u sledeću fazu.

Poslednji trag LLVM međukoda koji je opstao u programu a da je potrebno da se eliminiše su virutelni registri. U toku izvršavanja program će imati ograničen broj registara i ne može svaki od njih da se koristi za svaku operaciju. Dodeljivanje registara je korak kada se virtuelni registri zamenjuju konkretnim registrima za ciljnu arhitekturu. Po potrebi dodaju se nove instrukcije za čuvanje i učitavanje vred-

nosti registara. Dobijeni SelectionDAG predstavlja instrukcije potpuno ispravnog MIR programa. Ostalo je još da se one rasporede u linearni redosled uz poštovanje zavisnosti između čvorova. Ovo rezultuje kodom u MIR obliku.

I na ovom nivou postoje optimizacioni prolazi. Optimizacije na ovom nivou su vezane za ciljnu arhitekturu. Svi mašinski zavisni prolazi nasleđuju klasu MachineFunctionPass i implementiraju funkciju runOnMachineFunction koja se poziva za svaku funkciju u izvornom kodu. Način izvršavanja prolaza je sličan kao za mašinski nezavisan međukod.

Poslednji prolaz na MIR kodu je AsmPrinter koji emituje asmeblerski ili objektni kôd za ciljnu arhitekturu. Na ovom mestu se završava zadatak kompajera. Dalje, ukoliko je emitovan asemblerski kôd on se prevodi do objektnog koristeći asmebler. Objektni kôd se povezuje sa bibliotekama i drugim objektnim kodom pomoću povezivača (eng. linker) i dobija se izvršni fajl.

Alat koji obavlja posao zadnjeg dela kompajlera je 11c. Njemu se opciono zadaje vrsta izlaza (asemblerski ili objektni kôd) i nivo optimizacije. Bitan parametar koji 11c prihvata je ciljna arhitektura. Ona se zadaje argumentom -mtriple i vrednosti u vidu niske koja sadrži arhitekturu, proizvođača, operativni sistem i okruženje. Komanda za prevođenje optimizovanog mašinski nezavisnog međukoda do asemblerskog fajla je prikazana u listingu 2.6.

```
llc -filetype=asm -mtriple="x86_64-unknown-linux-gnu" -o output.s \rightarrow input_opt.ll
```

Slika 2.6:

Glava 3

Debageri

Prilikom programiranja bilo kog većeg projekta, neminovno je da ce doći do propusta. Propusti se odnose na bilo kakvo ponašanje programa koje nije u skladu sa namerom programera. U zavisnosti od komponente programa u kojoj se propust ispoljava, posledice mogu da budu više ili manje ozbiljne. Na primer, greška u korisničkom interfejsu ima dosta manje posledice od greške u sistemu obrade novca u banci. Svakako, svi primećeni propusti trebaju biti popravljeni pre objavljivanja nove verzije softvera.

Proces pronalaženja, reprodukovanja, analiziranja i popravljanja grešaka u programu naziva se debagovanje. Jedan od osnovnih načina je debagovanje štampanjem (eng. print debugging). Ono podrazumeva izmenu izvornog koda tako da ispisuje poruke i vrednosti promenljivih u glavnim koracima dela koda za koje programer smatra da su razlog za postojanje greške. Za sitnije greške ovo je sasvim prihvatljiv način za njihovo rešavanje. Mana tog pristupa je potreba za ponovnom kompilacijom celog programa svaki put kada se dodaje ili menja ispis. Kompilacija velikih projekata može da traje baš dugo, tako da se ovaj pristup ne isplati uvek. Alternativa je korišćenje posebnog alata namenjenog za ovu situaciju.

Debager je softverski alat koji olakšava proces debagovanja. On pruža interaktivan vid izvršavanja programa gde korisnik zadaje komande za izvršavanje programa i proveru vrednosti promenljivih. Umesto izmene izvornog koda, debager direktno ispituje i modifikuje program dok se izvršava. On uz pomoć operativnog sistema dobija potpunu kontrolu nad izvršavanjem programa. To mu daje pristup za čitanje i pisanje cele memorije programa dok se izvršava, uključujući i instrukcije koje će se izvršiti. Na taj način debager može i da kotroliše tok izvršavanja tog programa. Neke od funkcionalnosti debagera su:

- Evaluiranje vrednosti izraza Kada je proces zaustavljen na nekom mestu u kodu, korisnik želi da proveri vrednosti promenljivih. Neki debageri osim toga podržavaju i izračunavanje proizvoljnih izraza koji uključuju promenljive i funkcije programa koji se debaguje.
- Izvršavanje korak po korak Najčešći i najjednostavniji vid kretanja kroz program. Omogućava kontrolisano izvršavanje samo određenog dela koda. Korak može da označava jednu instrukciju, jedan red ili jednu funkciju.
- Postavljanje tačaka prekida Ukoliko programer već naslućuje koji deo koda izaziva problem, on ne želi da izvršava korak po korak program dok se ne dostigne taj deo. Umesto toga može da postavi tačku prekida (eng. breakpoint) na to mesto i pusti program da se sam izvršava. Svaki put kada se dostigne tačka prekida proces će biti zaustavljen.
- Praćenje vrednosti promenljivih Neki bagovi su izazvani neočekivanom promenom vrednosti neke promenljive. Pogodan način za otkrivanje trenutka kada se to desi je postavljanjem tačke prekida nad podatkom (eng. watchpoint). Promenom vrednosti na toj adresi će se zaustaviti proces i kontrola se vratiti korisniku.
- Pregled stek okvira Pronalazak mesta gde je greška ispoljena nije uvek dovoljno da se odredi gde ona nastaje. Taj deo koda se možda poziva sa više mesta i potrebno je odrediti koji od njih je izazvao problem. Pregledom stek okvira korisnik dobija uvid u istoriju svih poziva funkcija od početne funkcije.
- Izvršavanje programa unazad Nekada korisnik uoči problem tek nekoliko koraka nakon što je on nastao. Napredni debageri imaju podršku za poništavanje izvršenih instrukcija. Programski brojač se pomera unazad i sva izmenjena memorija se vraća na prethodno stanje.

Najpoznatiji debageri za jezike C i C++ su GDB, LLDB i $Microsoft\ Visual\ Studio\ Debugger.$

Tradicionalan način korišćenja debagera je putem komandne linije. Sve operacije se izvršavaju zadavanjem komande u tekstualnom obliku u formatu koji debager propisuje. Upotrebom komande za pokretanje dela ili celog programa korisnik više ne može da zadaje nove komande sve dok se prethodna komanda ne izvrši do kraja. Problem sa ovim vidom upotrebe je što korisnik mora da napamet zna strukturu

komandi ili da otvara dokumentaciju. Drugi način za upotrebu debagera je pomoću integrisanih razvojnih okruženja (eng. integrated development environment). Mnoga okruženja ugrađuju debager u svoj grafički korisnički interfejs (eng. graphical user interface). Postojanje grafičkih elemenata olakšava posao korisniku zato što ne mora da memoriše sve komande. Dovoljno je da pritisne odgovarajuće dugme ili na neki način izmeni neki drugi element. Ovo je najpogodniji način za nove korisnike da nauče da koriste debager. Postoji i sredina između prethodna dva načina upotrebe u vidu tekstualnog korisničkog interfejsa (eng. textual user interface). Umesto odvojenog prozora, i dalje se koristi komanda linija, ali je ona napravljena tako da liči na grafičko okruženje. Kako ne postoji podrška za kursor, komande se zadaju prečicama na tastaturi.

U nastavku će prvo biti objašnjen koncept informacija za debagovanje, a zatim će biti opisan format DWARF koji služi za zapisivanje tih informacija. Na kraju poglavlja je predstavljen debager LLDB i neki ključni delovi njegove implementacije.

3.1 Informacije za debagovanje

Za uspešno debagovanje programa na nivou izvornog koda (eng. source level debugging) potrebna je podrška kompajlera da sačuva informacije o tom kodu do izvršnog fajla. Pored mašinskog koda, kompajler takođe, ako mu je zatraženo, generiše i dodatne informacije koje se koriste za debagovanje. Između ostalog, one uključuju mapiranja mašinskih instrukcija u lokacije u izvornom kodu, imena funkcija i promenjivih itd. Sve te informacije zauzimaju dodatnu memoriju u krajnjem izvršnom fajlu i produžavaju vreme kompilacije. Iz tog razloga, one se podrazmevano ne generišu, već je potrebno eksplicitno navesti kompajleru da treba to da uradi. Kompajler LLVM generiše ove podatke dodavanjem zastavice -g u okviru komande za kompilaciju.

Većina informacija za debagovanje nastaju u prednjem delu kompjalera, pošto je on zadužen za analiziranja izvornog koda, i prosleđuju se kroz ostale faze kompilacije gde se usput dopunjuju novim podacima kada oni postanu dostupni (npr. lokacije promenljivih za vreme izvršavanja). Očuvanje informacija za debagovanje nailazi na problem kada se uključe kompajlerske optimizacije. Prilikom primene optimizacija, informacije za debagovanje i dalje treba reflektuju izvorni kod, a ne njegovu optimizovanu verziju. Što se više krajnji program razlikuje od izvornog koda postaje teže očuvati informacije, a nekada je to čak potpuno nemoguće. U slučaju da je

moguće izabrati između nepotpunih informacija ili informacije koje ne odgovaraju u potpunosti izvornom kodu, bolje je izabrati prvu opciju. Ovo je jedan od najvećih izazova pisanja optimizacija. Jednostavno rešenje je isključiti kompajlerske optimizacije prilikom debagovanja i ono može da bude pogodno za neke korisnike. Ipak, postoje situacije kada je potrebno prevesti program sa optimizacijama. Na primer u slučaju da se program kompajlira za računar sa malom količinom memorije gde ne može da se kompletno smesti ukoliko nije optimizovan za memoriju. Drugi problem prevođenja bez optimizacija je što se program onda razlikuje od verzije koja se isporučuje klijentu i moguće je da se bag ispoljava samo u toj verziji. Iz prethodno navedenih razloga se posebna pažnja prilikom pisanja optmizacija daje održavanju informacija za debagovanje.

Izvršni fajl je podeljen u nekoliko delova koji se nazivaju segmenti. Najbitniji među njima su tekst segment gde se nalaze instrukcije programa, segment inicijalizovanih podataka i segment neinicijalizovanih podataka. Pored njih mogu da postoje i drugi segmenti, na primer za podatke o razmotavanju steka u slučaju greške. Informacije za debagovanje ne diraju nijedan od prethodnih segmenata već definišu nove kako ne bi uticali na postojeće podatke. Broj i naziv novih segmenata zavisi od formata za zapisivanje informacija za debagovanje koji se koristi. Najpopularniji među njima su format CodeView za Windows sisteme i format DWARF za sisteme UNIX tipa.

Postojanje standardizovanih formata ima veliki značaj. Ono omogućava korišćenje debagera nezavisno od kompajlera kojim je program preveden. Bitno je samo da oba koriste isti format. Ukoliko bi svaki kompajler pisao informacije za debagovanje u nekom ličnom (eng. propriatery) formatu, on bi mogao da se koristi samo sa odgovarajućim debagerom. Zbog standardizovanih formata, program preveden na primer kompajlerom GCC može da se debaguje debagerom LLDB. Iako koriste iste formate, ne mora da znači da će bilo koja dva debagera moći u potpunosti da iskoriste sve dostupne informacije za debagovanje ili da će ih korisiti na iste načine.

3.2 Format DWARF

DWARF je standardizovan format za zapisivanje informacija za debagovanje. Originalno je osmišljen da radi uz format ELF koji se koristi za biblioteke, izvršni i objektni kôd, ali podržava i druge formate. Postoji podrška za programske jezike C, C++, Ada, Fortran i COBOL, ali je omogućeno proširenje i za druge jezike. Ovaj

format se koristi na UNIX sistemima što uključuje *Linux* distribucije i *macOS*. Postojalo je nekoliko revizija standarda do sada, a trenutno je aktuelna verzija 5 koja će biti podrazumevana u nastavku rada.

Sve informacije za debagovanje su raspoređene u nove sekcije izvršnog fajla koje počinju prefiksom .debug_. Neke od najbitnijih su [4]:

- .debug_info Glavna sekcija za debagovanje. Sadrži skoro sve informacije o entitetima iz izvornog koda.
- .debug_line Tabela adresa instrukcija u izvršnom fajlu i odgovarajućih lokacija u izvornom kodu. Takođe sadrži dodatne podatke o granicama prologa i epiloga funkcija.
- .debug_frame Podaci o načinu razmotavanja stek okvira.
- .debug_loclists Lokacije skladištenja promenljivih za vreme izvršavanja. Za jednu promenljivu može da postoji više lokacija na primer ako se promeni registar u kome je smeštena.
- .debug_abbrev Skraćenice za zapisivanje informacija u .debug_info sekciji. Koristi se za kompresovanje podataka.
- .debug_str Tabela niski koje se koriste u .debug_info sekciji.

Podaci u sekciji .debug_info su predstavljeni pomoću osnovnih jedinica (eng. Debug Information Entry, DIE) organizovanih u drvoliku strukturu. Svaka jedinica ima etiketu (eng. tag) koja označava njen tip, dodatne informacije predstavljene atributima i može da ima druge jedinice kao decu. Svaka etiketa i atribut imaju numeričku vrednost koja služi za zapisivanje u računaru i ime u obliku niske koje služi čoveku za lako čitanje podataka. Standard propisuje validne etikete i atribute koje moraju da postoje za te etikete. Ideja je da svaki entitet programskog jezika bude opisan na ovaj način. U listingu 3.1 prikazan je primer opisa jedne promenljive. Značenja prikazanih atributa su objašnjena kasnije u odeljku.

Bitna odlika formata DWARF je njegova proširivost. Standard pruža način da se format dopuni novim etiketama i atributima od strane proizvođača kompajlera. Razni alati mogu zatim da koriste te podatke kako bi poboljšali svoju funkcionalnost. Sa druge strane, postojeći alati koji ne razumeju te podatke mogu samo da ih preskoče. Na taj način se održava kompatibilnost sa postojećim alatima. Slično važi za alate koji su napravljeni za starije verzije standarda. Bitna stvar pilikom dodavanja

```
DW_TAG_variable
    DW_AT_location (DW_OP_fbreg -8)
    DW_AT_name ("x")
    DW_AT_decl_file ("/home/vladimir/Documents/example.c")
    DW_AT_decl_line (2)
    DW_AT_type (0x00000052 "int")
```

Slika 3.1: Primer DWARF jedinice koja opisuje promenljivu

etiketa i atributa je da im se dodele numeričke vrednosti koje nisu već deo standarda i poželjno bi bilo da se takođe ne koriste od strane drugih proizvođača kompajlera. Raspon dozvoljenih vrednosti je dovoljno veliki da ne dođe do preklapanja vrednosti. Kompajleri često koriste samo neki mali opseg za svoje potrebe.

Etiketa označava neki entitet izvornog koda ili koncept programskog jezika. Naziv etikete ima prefiks DW_TAG_ posle kog može da sledi oznaka proizvođača ako je u pitanju proširenje. Neke od najbitnijih etiketa su:

- DW_TAG_compile_unit Predstavlja jednu kompilacionu jedinicu. Kao decu sadrži prostore imena (eng. *namespace*), funkcije, globalne promenljive itd.
- DW_TAG_subprogram Predstavlja jednu funkciju. Sadrži podatke o imenu, parametrima i opsegu funkcije u izvršnom fajlu, između ostalog.
- DW_TAG_call_site Označava mesto poziva funkcije. Sadrži referencu na jedinicu DW_TAG_subprogram za pozvanu funkciju i adresu povratka iz poziva.
- DW_TAG_variable Opisuje jednu promenljivu. Ima informacije o njenom imenu, lokaciji u izvršnom fajlu i mestu deklaracije u izvršnom kodu.
- DW_TAG_base_type Pruža informacije o osnovnim tipovima uključujući njihov način zapisa i veličinu. Postoje slične etikete za tipove nizova i niski.

Atributi opisuju svojstva objekata označenih etiketom uz koju stoje. Isti atribut može imati više interpretacija u zavisnosti od etikete, ali jedan atribut se ne može ponavljati više puta u osnovnoj jedinici. Redosled atributa unutar jedinice nije definisan i ne treba se oslanjati da će biti konzistentan. Slično kao za etiketa, atribut počinje niskom DW_AT_ posle koje može da sledi oznaka proizvođača ako je u pitanju proširenje. Neki od najbitnijih atributa su:

• DW_AT_name — Može da opisuje ime funkcije, promenljive, labele itd.

- DW_AT_low_pc, DW_AT_high_pc Oba atributa zajedno opisuju opseg adresa. To može da bude opseg kompilacione jedinice, funkcije, postojanja promenljive itd. Ukoliko ne postoje informacije o obe granice, mogu se koristiti i odvojeno.
- DW_AT_decl_file Fajl izvornog koda u kome je deklarisan objekat.
- DW_AT_decl_line Red u izvornom kodu na kome je deklarisan objekat.
- DW_AT_decl_col Kolona u izvornom kodu na kojoj je deklarisan objekat.
- DW_AT_type Može da označava različite stvari u zavisnosti od konteksta.
 Najčešće je u pitanju tip koji ima neka promenljiva ili povratna vrednost funkcije.

3.3 Debager LLDB

LLDB je debager koji se razvija kao deo projekta LLVM. Napravljen je kao skup ponovo upotrebljivih komponenti koje ekstenzivno koriste biblioteke iz LLVM projekta kao što su parser izraza biblioteke clang ili disasembler biblioteke LLVM [5]. Podržava programske jezike C, C++ i Objective-C i dostupan na svim popularnim operativnim sistemima: Windows, macOS i Linux. LLDB je podrazumevani debager u integrisanom razvojnom okruženju Apple Xcode i podržan je od strane drugih okruženja uključujući JetBrains CLion, QtCreator, Eclipse i VSCode.

Primarni vid upotrebe alata LLDB je putem komandne linije. Korisnik upravlja načinom izvršavanja debagovanog procesa tako što zadaje komande debageru. Te komande su uniformnog oblika. Prvo se zadaje objekat nad kojim treba izvršiti neku operaciju. To može biti proces, nit, tačka prekida itd. Posle toga sledi operacija koja će biti izvršena nad tim objektom. Raspoložive operacije zavise od objekta. U slučaju niti to mogu biti izvršavanja koraka, nastavak izvršavanja programa itd. Na kraju komande se nalaze opcije i argumenti ukoliko su potrebni. Na primer za postavljanje tačke prekida može se zadati ime funkcije na koju je treba postaviti. Najčešće korišćene komande imaju definisane skraćenice radi lakše upotrebe. Tako se izvršavanje jednog koraka bez ulaska u funkcije može učiniti komandom thread step-over, skraćenicom next ili samo n.

Izvorni kod projekta LLDB je dostupan u okviru repozitorijuma projekta LLVM, u direktorijumu 11db. Glavni deo debagera je implementiran kao biblioteka 1ibl1db tako da se mogu napraviti novi alati bazirani na njoj. Sama aplikacija LLDB je

jedan od tih alata. Njena implementacija se nalazi u folderu tools/Driver. Tu se samo obrađuju argumenti komandne linije i vrše pripreme za izvršavanje dok je debagovanje delegirano biblioteci.

Debager mora da bude sposoban da predstavi stanje programa koji se debaguje. Klase zadužene za to se nalaze u direktorijumu Target. Neke od najbitnijih su:

- Target Interfejs za kontrolu izvršavanja ciljnog programa. Zadužen je za kreiranje i modifikovanje tačaka prekida, obaveštavanje objekata kada nastane neki događaj (eng. *event*) i upravljanje procesa.
- Process Predstavlja proces koji se debaguje. Sadrži listu niti tog procesa i prosleđuje im događaje koje dobija od klase Target.
- Thread Jedna nit procesa koji se debaguje. Određuje način izvršavanja i sadrži listu stek okvira.
- StackFrame Stek okvir koji pripada jednoj niti procesa koji se debaguje. Stek oviri jedne niti su numerisani tako da najnoviji okvir ima indeks 0, njegov roditelj ima indeks 1, itd. Kroz instancu okvira je moguće pristupiti promenljivama koje su dostupne u tom trenutku izvršavanja.

Ovi podaci se ne održavaju ažurni u toku izvršavanja procesa već se računaju po potrebi kada se debagovan proces zaustavi.

Informacije za debagovanje su integrisane pomoću klasa u direktorijumu Symbol. Učitavanje i pristup tim informacijama je ostvaren kroz interfejs SymbolFile. Podržani formati za debagovanje su implementirani u vidu priključaka (eng. plug-ins) koji implementiraju taj interfejs. Za mnoge operacije u debageru potrebne su informacije o stanju programa. U izvornom kodu to stanje se naziva kontekst i skladišti se u objektima klase SybolContext. On sadrži podatke o ciljnom programu, modulu, kompilacionoj jedinici, funkciji, bloku koda, lokaciji u izvornom fajlu i simbolu. Ne moraju uvek da budu dostupni svi ti podaci, a nekada nisu ni svi dostupni. Kontekst može da se popunjava selektivno, samo podacima koji su potrebni za neku operaciju. Određivanje konteksta se radi na osnovu informacija za debagovanje. Klasa SymbolContextScope opisuje objekte koji su sposobni da odrede svoj kontekst. Nju nasleđuje skoro svaka klasa koja je sadržana u kontekstu. Izuzeci su klasa StackFrame koja je ne nasleđuje, ali jos uvek može da odredi kontekst na drugi način i LineEntry koji ne podžava tu operaciju jer je pomerena u CompileUnit. Najčešći načini dobijanja konteksta su preko adrese instrukcije u izvršnom fajlu ili

preko lokacije u izvornom kodu. Drugi način se svakako svodi na prvi određivanjem adrese na osnovu lokacije. Adresa koja se najviše koristi za određivanje konteksta je vrednost programskog brojača.

Glava 4

Optimizacija izdvajanjem koda

Izdvajanje koda (eng. outlining) je kompajlerska optimizacija koja smanjuje količinu memorijskog prostora koji zauzima program, ali pritom potencijalno povećava njegovo vreme izvršavanja. Ona pronalazi segmente koda (uzastopne nizove instrukcija) koji se ponavljaju u programu, izdvaja ih u zasebnu funkciju i menja pojavljivanja tog segmenta sa pozivom ka novoj funkciji. U nekim slučajevima moguće je da se ubrza i vreme potrebno za kompilaciju programa [9].

Ova optimizacija je posebno korisna za uređaje sa malom količinom memorije, najčešće uređajima sa ugrađenim računarom (eng. embedded devices) poput pametnih satova, mp3 plejera ili urađaja zasnovanih na razvojnom sistemu Arduino. Vreme izvršavanja programa može da bude oštećeno ako se izdvoji deo koda koji se bas često izvršava (eng. hotspot). To je zato što je poziv funkcije je skupa instrukcija. Takođe, osim samog poziva, stek mora da bude pripremljen za poziv i parametri premešteni na odgovarajuća mesta. Sve to dodaje trošak koji nije prethodno postojao. Izdvajanjem koda koji se retko izvršava, sa druge strane, moguće je da dođe do poboljšanja u vremenu izvršavanja zbog bolje organizacije keš memorije. Nažalost, u vreme kompilacije je teško odrediti koliko puta će se izvršiti segment koda, time ni razlika u vremenu izvršavanja programa nije lako predvidiva.

U listingu 1 je prikazan primer C koda. Redovi 11-14 i 16-19 predstavljaju dobre kandidate za izdvajanje. Vrše se iste operacije samo sa drugačijom promeljivom. Ukoliko se ovaj kôd prevede do asemblerskog koda komandama prikazanim u listingu 2 tako da se pokrene samo optimizacija izdvajanja koda, rezultujući kôd je prikazan u listingu 3. Može se primetiti da je kostruisana nova funkcija outlined_ir_func_0. Ona sadrži sve instrukcije iz izdvojenih redova, a ti redovi su zamenjeni pozivom ka toj funkciji.

```
int global;
1
2
    __attribute__((noinline)) int foo(int a, int b) {
3
      return a / b * 2;
4
   }
5
6
    int main() {
7
      int x = 0;
8
      int y = 1;
9
10
      int c1 = x + y;
11
12
      c1--;
      global += 2;
13
      foo(c1, global);
14
15
      int c2 = x + y;
16
      c2--;
17
18
      global += 2;
      foo(c2, global);
19
20
21
      return c1;
   }
22
```

Listing 1: Primer C programa koji je dobar kandidat za izdvajanje koda clang -Xclang -disable-llvm-passes -g -03 -S -emit-llvm test.c -o test.ll opt -passes="iroutliner" -ir-outlining-no-cost=true -S test.ll -o test_opt.ll llc -filetype=asm test_opt.ll -o test.s

Listing 2: Instrukcije za prevođenje koda sa uključenim izdvajanjem instrukcija

Ova optimizacija prestavlja suprotan proces poznatijoj optimizaciji, umetanju koda (eng. *inlining*). Umetanje koda podrazumeva zamenu poziva ka funkciji sa telom te funkcije. Najčešće se primenjuje na kratke i jednostavne funkcije, koje se pozivaju na više mesta. Time se poništava cena poziva funkcije, što poboljšava vreme izvršavanja, ali pritom pošto su neki delovi koda duplirani dolazi do povećanja memorijskog zauzeća koda.

Iako imaju suprotne efekte, obe optimizacije je moguće koristiti i zajedno, na primer za delimično umetanje [18]. Ova ideja koristi izdvajanje koda kako bi iz funkcije namenjene za umetanje bili izdvojeni "hladni" delovi koda i time se smanjile negativne posledice umetanja. U tom kontekstu izdvajanje koda ne traži sekvence koje se ponavljaju već koristi heuristike da pronađe kôd koji se retko izvršava.

U jezicima C i C++ postoji ključna reč inline koja nagoveštava kompajleru da

```
# @main
1
   main:
   .Lfunc_begin1:
2
        .loc 0 11 0 is_stmt 1
                                                 # outline.c:11:0
3
       .cfi_startproc
4
5
               %rbx, %rdi
6
       movq
               %r14, %rsi
       movq
7
                outlined_ir_func_0
8
       callq
9
10
       movq
               %rbx, %rdi
               %r14, %rsi
11
       movq
                outlined_ir_func_0
12
       callq
13
            outlined_ir_func_0,@function # -- Begin function outlined_ir_func_0
14
     .type
   outlined_ir_func_0:
                                            # @outlined_ir_func_0
15
    .Lfunc_begin2:
16
        .loc 0 0 0 is_stmt 1
                                                 # outline.c:0:0
17
18
        .cfi_startproc
19
```

Listing 3: Isečci iz asemblerskog koda koji sadrži funkciju dobijenu izdvajanjem koda

primeni umetanje koda na označenu funkciju. Kompajler nije primoran da primeni optimizaciju, već je slobodan da izabere da li će funkciju umetnuti ili ostaviti poziv. Za razliku od toga, za izdvajanje koda ne postoji sličan mehanizam. Ukoliko kompajler podržava ovu optimizaciju, na njemu je da izabere koji delovi koda će biti izdvojeni. Ova optimizacija nije podrazumevano uključena, već programer može da je uključi na podržanim kompajlerima najčešće kompilacijom programa sa opcijom -0s (ili -0z za clang) koja optimizuje program za memoriju umesto za vreme.

4.1 Implementacija u kompajleru LLVM

Kompajler LLVM, kao jedan od najpopularnijih kompajlera za jezik C++ ima podršku za veliki broj optimizacija. Jedna od tih optimizacija je i izdvajanje koda. Postoje dve implementacije izdvajanja koda u okviru kompajlera LLVM:

- 1. MachineOutliner na mašinski zavisnom međukodu (MIR) [14]
- 2. IROutliner na mašinski nezavisnom međukodu (IR) [12]

Obe su implementirane kao prolazi (eng. pass) koji rade na nivou modula tako da omoguće izdvajanje koda iz različitih funkcija. Ideja je da obe implementacije komplementiraju jedna drugu i daju bolje rezultate nego ako bi se koristila samo

jedna od njih. Oba mesta implementacije imaju svoje prednosti i mane. Na mašinski zavisnom međukodu su dostupne informacije o ciljnoj arhitekturi čime je moguće dosta bolje proceniti cene izdvajanja instrukcija. Bolji model cena instrukcija bitno utiče na određivanje delova koda koji će biti izdvojeni. Problem na ovom nivou je što je u tom trenutku već izvršena alokacija registara. Kandidati za izdvajanje su ograničeni samo na sekvence koje koriste iste registre, iako možda postoji više sekvenci koje vrše isto izračunavanje samo sa drugim registrima. Sa druge strane, na mašinski nezavisnom međukodu se koriste virtuelni registri. Oni ne moraju da se poklapaju između sekvenci tako da je moguće izdvojiti mnogo veći deo koda. Međutim ovde se sada javlja problem procene dobitka memorije zato što se bez konkretne ciljne arhitekture ne može odrediti veličina instrukcija. Zbog korišćenja procena za cene instrukcija u obe implementacija je moguće da rezultat izdvajanja koda ima veću veličinu od početnog koda.

Obe implementacije se zasnivaju na istoj ideji, samo su adaptirane za međukod koji optimizuju. U nastavku će prvo biti objašnjen opšti algoritam, a zatim specifičnosti obe implementacije.

Opšti algoritam za izdvajanje koda

Opšti algoritam za izdvajanje koda sadrži dva osnovna koraka: odabir kandidata i izdvajanje koda.

Algoritam za odabir kandidata se zasniva na ideji da se program može tretirati kao niz numeričkih vrednosti gde se svakoj instrukciji dodeljuje jedna vrednost. Instrukcije se dele u tri grupe:

- Legalne instrukcije su one koje je dozvoljeno izdvojiti. Tu spada većina instrukcija: aritmetičke, logičke...
- Ilegalne instrukcije su one čije izdvajanje je zabranjeno kao što su pozivi funkcija ili instrukcije vezane za obradu grešaka.
- Nevidljive instrukcije ne utiču na izdvajanje, ovo su primarno instrukcije koje se koriste za debagovanje.

Pojedinačne vrednosti dodeljene instrukcijama se nadovezuju za svaki osnovni blok i svaki od njih se terminira jedinstvenom vrednosti kako bi se sprečilo izdvajanje koda preko granice blokova. Nadovezivanjem tih reprezentacija osnovnih blokova se dobija reprezentacija celog programa.

Nad takvom reprezentacijom programa sada mogu da se primene algoritmi za traženje ponavljajućih podniski (eng. longest repeated substring). Implementirani algoritam korsiti sufiksno stablo. Sufiksno stablo je struktura podataka koja omogućava efikasno izvršavanje nekih algoritama nad niskama. Formalno, sufiksno stablo niske S dužine n je korensko stablo za koje važi:

- \bullet stablo ima tačno n listova koji su numerisani od 1 do n
- osim korena, svaki unutrašnji čvor ima bar 2 deteta
- ullet svaka grana je označena nepraznom podniskom niske S
- nikoje dve grane koje polaze iz istog čvora nemaju zajednički prefiks
- niska dobijena konkatenacijom oznaka svih grana na putu od korena do lista numerisanog brojem i je sufiks niske S koji počinje od i-tog karaktera

Ovo stablo se sagradi u linearnoj složenosti u odnosu na broj karaktera niske pomoću Ukonenovog algoritma [17]. Broj čvorova u ovom stablu je linearno zavisan od broja karaktera, što znači da je obilazak ovog stabla takođe linearne složenosti. Traženje svih ponavljajućih podniski se može obaviti jednostavnim obilaskom stabla, takođe linearne složenosti.

Kada se odrede kandidati prelazi se u fazu izdvajanja koda. U petlji se odabira grupa kandidata za izdvajanje sa najvećim izračunatim doprinosom. Način računanja doprinosa zavisi od implementacije. U oba slučaja se dobija kao procena razlike u veličini programa ukoliko se grupa ne izdvoji i ako se izdvoji. Za odabranu grupu se generiše nova funkcija, a svi kandidati se zamenjuju pozivom te funkcije. Pritom se pazi da se održi semantika koda na tom međukodu. Posle svakog odabira kandidata, ta grupa kao i svi drugi kandidati koji se preklapaju sa njom se brišu iz sufiksnog stabla i postupak se ponavlja sve dok postoje grupe koje sa pozitivnim doprinosom. Ukoliko ih više nema, prolaz izdvajanja koda je završen.

Specifičnosti na mašinski zavisnom međukodu

Izdvajanje koda na mašinski zavisnom međukodu je implementirano u klasi MachineOutliner. Ovo je jednostavnija od dve implementacije. U nastavku će biti objašnjeni algoritmi za heširanje, procenu dobitka i način generisanja izdvojenog koda.

Heširanje instrukcija na ovom nivou je jednostavno. Poređenje se vrši po jednakosti. Dakle instrukcija i operandi moraju da budu identični. To predstavlja jedno od najvećih ograničenja na ovom nivou. Ukoliko dve sekvence vrše isto izračunavanje ali njihovim operandima su dodeljeni različiti registri, neće biti moguće izdvojiti taj kôd. Još uvek važi klasifikacija instrukcija, tako da instrukcije klasifikovane kao ilegalne nije moguće izdvojiti. Klasifikaciju instrukcija radi TargetInstrInfo.

Procena dobitka memorije se računa kao razlika između veličine programa bez i sa uključenom optimizacijom. Kako se ona radi na nivou jedne grupe kandidata, dovoljno je posmatrati samo instrukcije koje pripadaju toj grupi. Veličina grupe kadidata bez optimizacije ne mora da se proceni, jer je već dostupna kao proizvod veličine jedne grupe i ukupnog broja grupa. Veličina sa primenjenom optimizacijom zahteva više računa. Još uvek postoji jedan kandidat iz grupe koji predstavlja telo izdvojene funkcije. On se sabira sa procenama cena svih poziva izdvojene funkcije i cenama dodatnih instrukcija za kreiranje novog okvira za funkciju. Sve to ukupno čini procenu sa uključenom optimizacijom. Cene instrukcija na ciljnoj arhitekturi kao i procene poziva i se dobijaju kroz interfejs TargetInstrInfo.

Grupe se sortiraju po benefitu. Izbacuju se svi kandidati koji se preklapaju sa prethodno izdvojenim kodom. Generiše se nova funckija sa imenom OUTLINED_FUNCTION_X gde je X redni broj izdvojene funkcije. Kopiraju se instrukcije proizvoljnog kandidata, generišu se informacije za debagovanje. Svi kandidati se zamenjuju pozivom ka generisanoj funkciji.

Specifičnosti na mašinski nezavisnom međukodu

Izdvajanje koda na mašinski nezavisnom međukodu radi prolaz koji se zove IROutliner. Ona je znatno kompilkovanija nego mašinski nezavisna varijanta, ali pruža više mogućnosti za izdvajanje. U nastavku će biti objašnjeni algoritmi za heširanje, procenu dobitka i način generisanja izdvojenog koda.

Za određivanje kandidata se koristi pomoćna analiza, IRSimilarityIdentifier. Umesto poređenja celih instrukcija, poredi se samo tip instrukcije i operanda i dodatni parametri za neke instrukcije (npr. ime pozvane funkcije ili tip predikta za instrukciju poređenja). Operandi ne utiču na heš vrednost instrukcije zato što se oni mogu izvući kao argumenti izdvojene funckije. Zbog toga je moguće izdvajanje dosta više koda.

Dobitak se računa slično kao na mašinski nezavisnom nivou, kao razlika bez i sa uključenom optimizacijom. Kako je ovaj međukod dalji od krajnjeg koda, procena

postaje teža jer se oslanja na manje precizne podatke. Cena bez optimizacije se ovaj put računa kao suma procena veličina svih kandidata. Cena sa optimizacijom sadrži prosečnu veličinu kandidata i procene veličina instrukcija za smeštanje i učitavanje potrebnih argumenta. Procene cena instrukcija nakon transformacije na ciljnu arhitekturu se dobija kroz interfejs TargetTransformInfo.

Usled postojanja argumenata izdvojenoj funkciji, način izdvajanja postaje komplikovaniji. Kandidati se izdvajaju iz dva pokušaja. Prvi put kada se izdvoje određuju se svi argumenti koje će funkcija imati. Svi potrebni argumenti su poznati tek nakon prvog prolaska tako da se drugi put se izdvajanje vrši uz zamenu argumenata. Jedan od izdvojenih kandidata se proglašava za konačnu izdvojenu funkciju i njemu se dodeljuje ime outlined_ir_func_x gde je x redni broj izdvojene funkcije. Informacije iz svih izdvojenih kandidata se spajaju sa izabranom funkcijom i zatim brišu. Na kraju, svaki kandidat se zamenjuje pozivom ka funkciji prilikom čega se dodaju i instrukcije za čuvanje i učitavanje argumenata.

4.2 Izdvajanje koda i debag lokacije

Debag lokacije predstavljaju pozicije u izvornom kodu koje odgovaraju instrukciji u izvršnom fajlu. Sastoje se od fajla, reda i kolone. U idealnom slučaju, svaka instruckija u izvornom kodu bi trebalo da ima odgovarajuću lokaciju, ali to nije slučaj pogotovu u optimizovanom kodu. Veliki broj optimizacija menja kôd na način koji može da naruši tačnost debag lokacija. Neki od najčešćih slučajeva su brisanje nepotrebnih instrukcija ili pomeranja instruckija van tela petlje. Kompajleri se trude da održe što veću količinu debag lokacija, ali nekada to ili nije moguće ili nema smisla posle izvršavanja optimizacije.

U nastavku se podrazumeva da se koristi format DWARF za čuvanje informacija za debagovanje. Lokacije za debagovanje se interno čuvaju u tabeli linija u .debug_line sekciji izvršnog fajla. Ta tabela preslikava adresu iz tekst (kôd) segmenta izvršnog fajla na odgovarajuću lokaciju (fajl, red, kolona) u izvornom kodu i neke dodatne informacije o toj lokaciji. Format DWARF propisuje način enkodiranja tabele linija u vidu konačnog automata, ali postoje alati koji prikazuju podatke u obliku tabele. Listing 4 prikazuje upotrebu nekoliko alata za dekodiranje tabele linija, a u listingu 5 se nalazi primer jedne tabele.

Debageri prikazuju lokaciju iz tabele koja je vezana za prvu adresu koja je manja ili jednaka adresi instrukcije na kojoj je program zaustavljen. Na taj način ukoliko

```
llvm-dwarfdump --debug-line [file]
readelf -wL [file]
objdump -WL [file]
```

Listing 4: Komande za ispis tabele linija koristeći alate llvm-dwarfdump, readelf i objdump

Address	Line	Column	File	ISA	${\tt Discriminator}$	Flags	
0x0000000000401110	1	0	1	0	0	is_stmt	
0x000000000040111b	2	6	1	0	0	is_stmt	<pre>prologue_end</pre>
0x0000000000401122	3	3	1	0	0	is_stmt	
0x000000000040112b	4	2	1	0	0	is_stmt	
0x000000000040112f	4	2	1	0	0	is_stmt	end_sequence

Listing 5: Tabela linija ispisana pomoću alata llvm-dwarfdump

trenutna instrukcija nema svoju debag lokaciju, prikazaće se lokacija prve prethodne instrukcije koja ima lokaciju. Standard propisuje i specijalne debag lokacije koje se poznaju po tome sto imaju red 0. Ove lokacije znače da je kôd kompajlerski generisan i da ne postoji odgovarajuća lokacija u izvornom kodu. Prilikom izvršavanja programa red po red (koristeći komandu step u debageru LLDB) preskaču se sve instrukcije sa istim redom kao prethodna ili sa redom 0. Na instrukciju koja nema dodeljenu lokaciju je moguće stati izvršavanjem programa instrukciju po instrukciju, postavljanjem tačke prekida na adresu te instrukcije ili usled zaustavljanja programa zbog izuzetka koji se desio u toj instrukciji.

Prilikom izdvajanja koda jedna instrukcija ima više mogućih debag lokacija u zavisnosti od mesta poziva izdvojene funckije. Ovo predstavlja više problema:

- U vreme izvršavanja programa nije moguće odrediti koja od ovih lokacija je korektna bez dodatnih informacija
- Format DWARF ne podržava postojanje više različitih lokacija za istu adresu [3]

Radi održavanja korektnosti, prilikom izdvajanja koda brišu se lokacije svih izdvojenih instrukcija. Kao posledica toga mogu se javiti nepogodnosti prilikom debagovanja:

 Izvršavanje korak po korak pravi velike skokove kada dođe do izdvojenog koda, bez bilo kakvog obaveštenja korisniku Postavljanje tačaka prekida na izdvojenu instrukciju precizirajući njen red nije moguće

Primer debagovanja sa izdvojenim kodom je prikazan u listingu 6. Redovi 11-14 i 16-19 su izdvojeni u funkciju. Kada debager koračanjem naredbu po naredbu dođe do nekog od tih regiona, u sledećem koraku ga celog preskoči.

```
$ 11db outline
(11db) breakpoint set 11
(lldb) run
    8
                 int x = 0;
    9
                 int y = 1;
    10
 -> 11
                 int c1 = x + y;
                 c1--;
    12
    13
                 global += 2;
                 foo(c1, global);
    14
(11db) next
    13
                 global += 2;
                 foo(c1, global);
    14
    15
 -> 16
                 int c2 = x + y;
    17
                 c2--;
    18
                 global += 2;
                 foo(c2, global);
    19
(11db) next
    18
                 global += 2;
    19
                 foo(c2, global);
    20
 -> 21
                 return 0;
          }
    22
```

Listing 6: Proces debagovanja programa sa izvojenim kodom. Izdvojeni delovi koda su preskočeni prilikom izvršavanja korak po korak.

Glava 5

Implementacija rešenja

Implementacija rešenja nadograđuje verziju 16 projekta LLVM, što je najnovija stabilna vezija u vreme pisanja rada. Celokupan izvorni kôd je dostupan na servisu GitHub na adresi https://github.com/vvuksanovic/llvm-project/tree/outline-debug-info. Komande za kompilaciju projekta su prikazane u listingu 5.1.

```
$ git clone https://github.com/vvuksanovic/llvm-project.git
$ cd llvm-project
$ git checkout outline-debug-info
$ mkdir build && cd build
$ cmake -G Ninja -DCMAKE_ENABLE_PROJECTS="clang;lldb" -DCMAKE_BUILD_TYPE=Release
$ ninja
```

Slika 5.1: Komande za prevođenje kompajlera LLVM

Rešenje se sastoji iz dva dela. Prvo je potrebno u okviru kompajlera generisati potrebne informacije za debagovanje, a zatim ih iz debagera iskoristiti za poboljšanje procesa debagovanja. U nastavku će redom biti opisana oba dela implementacije.

5.1 Implementacija u kompajleru

Zadatak ovog dela je da prilikom primene optimizacije izdvajanja funkcija zapamti originalne lokacije u izvornom kodu, prenese ih kroz sve faze kompilacije i ispiše ih u sekciju za debagovanje izvršnog fajla. Potrebne informacije se generišu u okviru implementacija optimizacije, u prolazima IROutliner i MachineOutliner.

Kako tabela linija ne podržava duplirane vrednosti adrese, ona nije u opticaju za čuvanje vrednosti. Ideja je da se debag lokacije sačuvaju u .debug_info sekciji umesto u .debug_line. Verzija 5 standarda DWARF je uvela novu etiketu, DW_TAG_call_site, koja bi trebalo da sadrži podatke o mestu poziva funkcije [10]. Trenutno se već koristi za pružanje informacija o vrednostima parametara prilikom poziva funkcije [11] i da li je poziv repni ili repni rekuzivan. Ovo je pogodno mesto za dodavanje informacija o izdvojenim instrukcijama zato što su one baš vezane za mesto poziva izdvojene funkcije.

Implementacija trenutno podržava čuvanje podataka na prilikom izdvajanja koda mašinski nezavisnoj međureprezentaciji. Kako to uključuje spuštanje kroz mašinski zavisnu reprezentaciju, jednostavno je dodati podršku za izdvajanje koda i na toj reprezentaciji. Jedini deo koji nedostaje je generisanje podataka. Za izbor instrukcija se koristi SelectionDAG implementacija, tako da će čuvanje podataka raditi za sve podržane arhitekture. Glavni fokus ove implementacije je x86_64 arhitektura, ali količina koda specifičnog za tu arhitekturu je minimalna.

Dakle, debag lokacije moraju da budu prenesene od IROutliner optimizacionog prolaza, kroz izbor instrukcija do mašinski zavisnog međukoda i konačno do asemblerskog fajla u okviru debag sekcije. Svaka od navedenih stavki je detaljnije objašnjena u nastavku.

Čuvanje debag lokacija prilikom optimizacije

Kao što je objašnjeno u poglavlju 4.2, optimizacioni prolaz IROutliner prilikom izdvajanja instrukcija briše sve podatke o njihovim lokacijama u izvornom kodu. Kako izdvajanje funkcija ostavlja kôd sa manje instrukcija nego sto je bilo pre toga, ne postoji dovoljno mesta da se smeste potrebne informacije. Kao prvi korak očuvanju ovih podataka ovaj rad uvodi novu unutrašnju (eng. *intrinsic*) funkciju za debagovanje, llvm.dbg.outlined, čiji poziv se generiše odmah posle poziva ka izdvojenoj funkciji i dodatno je opisuje odgovarajućom debag lokacijom izdvojene instrukcije.

Unutrašnje funkcije su funkcije koje su ugradjene u sami kompajler takve da on može da ih implementira na optimalan način [15]. One predstavljaju mehanizam proširenja LLVM jezika takav da ne zahteva modifikaciju svih prolaza kada se nešto doda u jezik. Imena svih unutrašnjih funkcija počinju prefiksom "11vm.", on će u nastavku biti izostavljen. Posebnu klasu unutrašnjih funkcija čine funkcije za debagovanje. U ovu grupu spadaju dbg.declare, dbg.value i dbg.addr za praćenje

promenljivih i dbg.label za obeležavanje labela u izvornom kodu. One ne utiču na krajnji izvršni kôd nego se koriste za popunjavanje informacija za debagovanje.

Kao pomoć za identifikovanje izdvojenih instrukcija, uveden je i novi metapodatak outline_id. Taj metapodatak će se nalaziti uz svaku izdvojenu instrukciju kao i uz instrukciju poziva izdvojene funkcije. On nema nikakve dodatne podatke nego je umesto toga deklarisan kao jedinstven. To znači da će se za svaku upotrebu kreirati nova instanca umesto da se ponovo koristi postojeća kao što je podrazumevano.

Sada kada postoji način za referisanje instrukcija, moguće je definisati deklaraciju dbg.outlined funkcije. Deklaracija ima dva parametra, oba su metapodaci koji pokazuju na outline_id identifikatore redom za odgovarajuću izdvojenu instrukciju i instrukciju poziva uz koju stoji. Ovi parametri ne mogu da budu zaključeni implicitno na osnovu mesta na kom se nalaze zbog potencijalnih optimizacija koje mogu da se izvrše kao i promene redosleda instrukcija (npr. u izdvojenoj funkciji). Dodatno, instrukcija sadrži i debag lokaciju koju pruzima od izdvojene instrukcije koju zamenjuje.

Kreiranje nove unutrašnje funkcije za debagovanje je veoma jednostavno i radi se na deklarativan način. Jedino što je potrebno uraditi je dodati deklaraciju u Intrinsics.td fajlu sa nazivom, u parametrima. Za lakše upravljanje tom funkcijom i njenim parametrima napravljen je novi tip instrukcije DbgOutlinedInst koja nasleđuje DbgInfoIntrinsic klasu. Ta instrukcija služi kao omotač i koristi se kao alias za instrukciju poziva dbg.outlined funkcije. Instanciranje ove instrukcije se radi uz pomoć nove funkcije u klasi DIBuilder. Metapodatak outline_id se registruje u definicionom fajlu FixedMetadataKinds.def. Implementacija se nalazi u klasi DebugInfoMetadata i nju je potrebno registrovati u Metadata.def. Dodatno, uvedena je podrška za čitanje i pisanje LLVM IR fajlova kao i za njihovu proveru ispravnosti.

Za svaku izdvojenu instrukciju koja ima debag lokaciju se generiše odgovarajuća dbg.outlined instrukcija i dodaje se posle instrukcije poziva. Isečak LLVM međukoda programa nakon izdvajanja funkcije je prikazan u listingu 5.2.

Funkcije generisane izdvajanjem koda je potrebno na neki način razlikovati od drugih funkcija. Trenutno se već u mašinski nezavisnom međukodu dodaje zastavica (eng. flag) DIFlagArtificial ali to nije dovoljno da se razlikuje od drugog kompajlerski generisanog koda. Iz tog razloga, dodata je nova vrsta zastavice, DIFlagOutlined, koja označava samo izdvojene funkcije. U kasnijoj fazi kompilacije ona će se prevesti u DWARF atribut DW_AT_LLVM_outlined. Nova zastavica se

```
define dso_local i32 @main() #2 !dbg !30 {
   call void @outlined_ir_func_0(ptr %x, ptr %y, ptr %c1), !dbg !44,
\rightarrow !outline_id !45
   call void @llvm.dbg.outlined(metadata !46, metadata !45), !dbg !44
   call void @llvm.dbg.outlined(metadata !47, metadata !45), !dbg !48
   call void @llvm.dbg.outlined(metadata !49, metadata !45), !dbg !50
   call void @llvm.dbg.outlined(metadata !51, metadata !45), !dbg !43
   call void @llvm.dbg.outlined(metadata !52, metadata !45), !dbg !53
   call void @llvm.dbg.outlined(metadata !54, metadata !45), !dbg !53
   call void @llvm.dbg.outlined(metadata !55, metadata !45), !dbg !53
   call void @llvm.dbg.outlined(metadata !56, metadata !45), !dbg !57
   call void @llvm.dbg.outlined(metadata !58, metadata !45), !dbg !57
   call void @llvm.dbg.outlined(metadata !59, metadata !45), !dbg !57
   call void @llvm.dbg.outlined(metadata !60, metadata !45), !dbg !61
   call void @llvm.dbg.outlined(metadata !62, metadata !45), !dbg !63
   call void @llvm.dbg.outlined(metadata !64, metadata !45), !dbg !65
}
define internal void @outlined_ir_func_0(ptr %0, ptr %1, ptr %2) {
   %3 = load i32, ptr %0, !outline_id !46
   %4 = load i32, ptr %1, !outline_id !47
   %add = add nsw i32 %3, %4, !outline_id !49
   store i32 %add, ptr %2, !outline_id !51
   %5 = load i32, ptr %2, !outline_id !52
   \%dec = add nsw i32 %5, -1, !outline_id !54
   store i32 %dec, ptr %2, !outline_id !55
   %6 = load i32, ptr @global, !outline_id !56
   %add1 = add nsw i32 %6, 2, !outline_id !58
   store i32 %add1, ptr @global, !outline_id !59
   %7 = load i32, ptr %2, !outline_id !60
   %8 = load i32, ptr @global, !outline_id !62
   %call = call i32 @foo(i32 noundef %7, i32 noundef %8), !outline_id !64
}
```

Slika 5.2: Primer LLVM međukoda nakon optimizacije izdvajanja koda sa novom instrukcijom i metapodatkom.

dodaje u trenutku generisanja izdvojene funkcije u klasi IROutliner, a stara zastavica DIFlagArtificial je zadržana radi održanja kompatibilnosti unazad. Pristup ovoj zastavici je omogućen dodavanjem isOutlined metode u okviru DISubprogram klase koja predstavlja metapodatak sa podacima o funkciji.

Čuvanje debag lokacija prilikom izbora instrukcija

Na kraju prethodne glave su potrebne informacije za debagovanje postale dostupne posle izvršavanja optimizacija na mašinski nezavisnom međukodu. Naredni korak je sprovesti te informacije do sledećeg nivoa, odnosno mašinski zavisnog međukoda. Proces konverzije iz mašinski nezavisnog do zavisnog međukoda u infrastrukturi LLVM se naziva izbor instrukcija. Postoji vise implementacija izbora instrukcija, ali u ovom radu je trenutno podržana samo implementacija SelectionDAG.

Od uvedenih podataka za potrebe ovog rada, za dbg.outlined i vezu između DIOutlineId i instrukcija za koje su vezane potrebno je implementirati dalje prevođenje. Svi metapodaci ostaju u istom obliku u ovoj fazi kompilacije. Na kraju iybora instrukcija sve dbg.outlined instrukcije će biti zamenjene ekvivalentnom MIR instrukcijom DBG_OUTLINED sa istim parametrima i debag lokacijom. Instrukcija DBG_OUTLINED je registrovana u definicionim fajlovima Target.td i TargetOpcodes.def. Klasa SelectionDAG tretira instrukcije za debagovanje drugačije od ostalih instrukcija. One se takođe pretvaraju u čvorove usmerenog aciklicnog grafa ali umesto da se ubace u usmeren aciklicni graf, one su ostavljene po strani u odvojenim strukturama podataka. Zahvaljujući ovome te instrukcije će ostati neizmenjene prilikom izvršavanja većine faza izbora instrukcija. Po ugledu na druge instrukcije za debagovanje, uveden je tip cvora SDDbgOutlined i dodato polje u klasi SelectionDAG za njihovo skladištenje. Kako se gradi objekat tipa SelectionDAG, sve dbg.outlined instrukcije se pretvaraju u SDDbgOutlined i čuvaju u novom polju. Na kraju izbora instrukcija, kada je potrebno poređati instrukcije svaki SDDbgOutlined sadrži redni broj koji je dobio prilikom konstrukcije i na osnovu njega se DBG_OUTLINED emituju na očekivanom mestu u kodu.

Na sličan način kao za čvorove instrukcija za debagovanje, tako se i podaci o outline_id metapodatku instrukcija čuva odvojeno od grafa. Konkretno, čuva se u novom polju u okviru promenljive SDCallSiteDbgInfo. To je mapa koja preslikava SDNode u objekat koji sadrži dodatne informacije o čvorovima. Prilikom emitovanja mašinskih instrukcija proverava se postojanje ovog podatka za svaku instrukciju i ukoliko postoji dodeljuje se instrukciji.

```
name: main
body:
   CALL64pcrel32 @outlined_ir_func_0, outline-id !45, debug-location !44
   ADJCALLSTACKUP64 0, 0, debug-location !44
   DBG_OUTLINED !46, !45, debug-location !44
   DBG_OUTLINED !47, !45, debug-location !48
   DBG_OUTLINED !49, !45, debug-location !50
   DBG_OUTLINED !51, !45, debug-location !43
   DBG_OUTLINED !52, !45, debug-location !53
   DBG_OUTLINED !54, !45, debug-location !53
   DBG_OUTLINED !55, !45, debug-location !53
   DBG_OUTLINED !56, !45, debug-location !57
   DBG_OUTLINED !58, !45, debug-location !57
   DBG_OUTLINED !59, !45, debug-location !57
   DBG_OUTLINED !60, !45, debug-location !61
   DBG_OUTLINED !62, !45, debug-location !63
   DBG_OUTLINED !64, !45, debug-location !65
```

Slika 5.3: Isečak LLVM mašinski zavisnog međukoda dobijen izborom instrukcija koda iz prethodne glave.

Najveća količina informacija se izgubi prilikom izbora instrukcija. Identifikatori koji stoje iz instrukcije se mogu izgubiti ako se instrukcija zameni drugom bez kopirnanja njenih dodatnih podataka. Na primer, prilikom spuštanja mašinski nezavisne instrukcije poziva funkcije na mašinski zavisan nivo za arhitekturu X86 pravi potpuno novi čvor. Zato što se outline_id čuva u mapi ciji je ključ SDNode, zamenom nekog čvora će se izgubiti ta veza osim ako se taj podatak eksplicitno prenese. Pomenuti primer je popravljen u implementaciji, ali još uvek postoji veliki broj slučajeva kada će se ovaj problem ispoljiti.

Isečak LLVM mašinski zavisnog međukoda programa nakon izdvajanja funkcije je prikazan u listingu 5.3.

Ispisivanje debag lokacija prilikom emitovanja asemblerskog koda

Poslednja faza kompilacije koju radi direktno kompajler je emitovanje asemblerskog koda. U okviru nje se mašinske instrukcije dobijene izborom instrukcija

pretvaraju u odgovarajuće asemblerske instrukcije za tu arhitekturu. U isto vreme se generišu i informacije za debagovanje u izabranom formatu. Sledeće faze kompilacije rade asembler i linker koji će bez problema preneti sve informacije redom do objektnog odnosno izvršnog fajla. Dakle ovo je poslednji korak koji je potrebno izmeniti za potrebe ovog rada.

Svi podaci o izdvojenim instrukcijama treba da se pretvore u informacije za debagovanje. Uključivanje informacija za debagovanje ne sme da menja krajnji kôd tako da nijedna instrukcija neće biti dodata u tekst segment programa. Ova implementacija podržava samo ispisivanje u formatu DWARF. Proizvođači kompajlera mogu da dodaju svoja proširenja standarda sve dok ne menjaju vrednosti propisane standardom DWARF. Kako se etikete i atributi mapiraju na celobrojne numeričke vrednosti, proizvođač može da koristi jedan slobodno izabran opseg vrednosti sve dok se ne preklapa sa opsegom nekog od drugih kompajlera. Što se tiče kompajlera LLVM, on uvodi svoja proširenja standarda DWARF koja se mogu prepoznati po tome što njihovi nazivi sadrže podnisku LLVM. Implementacija ovog rada se oslanja na nove vrste etiketa i atributa koji će biti opisani u nastavku.

Kao što je pomenuto na početku poglavlja, novi podaci će biti smešteni u okviru postojeće etikete DW_TAG_call_site koja opisuje poziv funkcije. Za svaku DBG_OUTLINED instrukciju u odgovarajućoj etiketi mesta poziva funkcije biće dodata novouvedena etiketa DW_TAG_LLVM_outlined_ref. Nova etiketa se zove DW_TAG_LLVM_outlined_ref i sadrži četiri atributa:

- DW_AT_decl_file Identifikator fajla lokacije u izvornom kodu
- DW_AT_decl_line Broj reda u izvornom kodu
- DW_AT_decl_column Broj kolone u izvornom kodu
- DW_AT_low_pc Adresu instrukcije u tekst segmentu programa. U ovom trenutku predstavljenu labelom ispred te intrukcije.

Informacije za debagovanje se u kompajleru LLVM generišu funkciju po funkciju. Međutim, po prirodi ovog zadatka uvek će postojati izdvojena funkcija koju je potrebno obraditi pre nego što je moguće obraditi funkcije koje je pozivaju. LLVM ne pruža mogućnost zadavanja ovakvih zavisnosti, tako da je rešenje pomeriti većinu poslova da se izvrše na samom kraju obrade modula. Obradom svake funkcije se rade potrebne pripreme i čuvaju informacije koje će se na kraju spojiti u konačnu reprezentaciju. Glavna klasa zadužena za upravljanje informacijama za debagovanje

na ovom nivou je DebugHandlerBase. To je bazna klasa koja radi opšte obrađivanje informacija zajedničko za sve formate za debagovanje. Za sve poslove vezane za konkretan format ona poziva virtuelne funkcije koje implementira odgovarajuća podklasa za taj format. Ovaj rad se fokusira na implementaciju DwarfDebug.

Prvi korak prema ispisivanju informacija za debagovanje je prikupljanje DBG_OUTLINED instrukcija iz prethodne faze kompilacije. Na početku obrade funkcije DebugHandlerBase poziva instancu klase DbgEntityHistoryCalculator da prođe kroz kôd i zapamti unutrašnje instrukcije za debagovanje. Ta klasa je proširena da isto to uradi i za DBG_OUTLINED instrukcije. Radi lakšeg budućeg pristupa, grupiše ih po njihovom drugom argumentu koji predstavlja outline_id instrukcije poziva. Svi prikupljeni podaci se smeštaju u polje klase DebugHandlerBase tako da je vidljivo i podklasama. Druga stvar koja se radi takođe na početku funkcije je zahtevanje za kreiranje labela ispred instrukcija u funkcijama generisanim izdvajanjem koda koje imaju outline_id. Te labele se dodaju tek prilikom obrađivanja instrukcije ispred koje treba da se smeste, tako da sve potrebne labele postoje tek na kraju obrađivanja cele funkcije. Celokupnu dalju obradu informacija radi instanca klase DwarfDebug. Na kraju obrade svake od funkcija iz korisničkog koda pozvana je funkcija endFunctionImpl. Ona prikuplja i emituje sve informacije za debagovanje koje su nastale prilikom obrade te funkcije. Te informacije uključuju:

- DWARF etikete koje predstavljaju mesto poziva funkcije i outline_id metapodatak uz instrukciju poziva za svaku funkciju nastalu izdvajanjem koda.
- Labele postavljene ispred svake izdvojene instrukcije zajedno sa njenim outline_id podatkom
- Sve ključne informacije iz DBG_OUTLINED instrukcija u novoj reprezentaciji vezanoj za DWARF umesto za MachineInstr.

Na kraju obrade modula sigurno su spremni svi neophodni podaci iz svih funkcija korisničkog koda. Spajanjem tih podataka na osnovu zajedničkih outline_id vrednosti lako je u postojeće etikete dodati sve potrebne informacije za debagovanje.

Funkcije za kreiranje novih i modifikovanje postojećih DWARF etiketa nalaze se u klasi DwarfCompileUnit. Tu su dodate funkcije za generisanje DW_TAG_LLVM_outlined_ref etiketa sa ranije opisanim poljima i dodata je pomoćna funkcija za ubacivanje tih etiketa u DW_TAG_call_site. Uz to, toj etiketi je dodat atribut DW_AT_LLVM_outlined koji označava da je to poziv izdvojene funkcije. Isti atribut se dodaje i etiketi te funk-

cije a ovde je dodat kako bi se kasnije brže odredilo da li se poziva izdvojena funkcija ili ne.

Što se tiče emitovanja instrukcija u tekst segment, u funkciju emitFunctionBody klase AsmPrinter je dodat slučaj za ispisivanje instrukcije DBG_OUTLINED koji ne radi ništa. Promenom ove implementacije da ispiše komentar može se potvrditi da su instrukcije DBG_OUTLINED još uvek prisutne i da se nalaze na očekivanom mestu u kodu.

Prethodnim modifikacijama omogućeno je prevođenje do asemblerskog fajla. Asembler nema predstavu o formatu ili informacijama za debagovanje i ne postoje posebne asemblerske direktive za njih. Umesto toga, sekcije za debagovanje se u asemblerskom kodu popunjavaju literalima koji imaju redosled i veličinu propisane formatom. Te vrednosti se direktno prenose u objektni i izvršni fajl. Ti literali imaju smisla samo kada se parsiraju u istom formatu u kom su zapisani. Jedan alat koji to može da uradi je 11vm-dwarfdump. Listing 5.4 prikazuje deo novih etiketa parsiranih iz objektnog fajla pomoću alata 11vm-dwarfdump. Kako bi imao podršku za prikazivanje ovih etiketa potrebno je koristiti verziju alata koja je sagrađena uz ovaj projekat.

```
0x00000093: DW_TAG_call_site
               DW_AT_call_origin
                                     (0x000000dc)
               DW_AT_call_return_pc (0x000000000001179)
               DW_AT_LLVM_outlined (true)
0x00000099: DW_TAG_LLVM_outlined_ref
               DW_AT_decl_file
                                     ("test.c")
               DW_AT_decl_line
                                     (11)
               DW_AT_decl_column
                                     (0x0b)
                                     (0x000000000001194)
               DW_AT_low_pc
0x0000009e: DW_TAG_LLVM_outlined_ref
               DW_AT_decl_file
                                     ("test.c")
               DW_AT_decl_line
                                     (11)
               DW_AT_decl_column
                                     (0x0f)
                                     (0x000000000001196)
               DW_AT_low_pc
```

Slika 5.4: Isečak DWARF stabla koji prikazuje etiketu poziva funkcije i njenu decu sa podacima o izdvojenim instrukcijama

5.2 Implementacija u debageru

Programi prevedeni kompajlerom sa izmenama iz prethodnog poglavlja uz neophodne opcije će sadržati debag informacije o izdvojenom kodu. Pošto implementacija predstavlja novo proširenje standarda DWARF, nijedan postojeći debager nema podršku za interpretiranje tih informacija. U ovom poglavlju će biti predstavljena implementirana podrška za uvedeno proširenje u debageru LLDB. Prvo će biti omogućeno učitavanje novih podataka, a zatim rešeni najveći nedostaci trenutne podrške za debagovanje izdvojenih instrukcija. To uključuje ispisivanje tačnih mesta u izvornom kodu kada se proces zaustavi, podršku za izvšavanje korak po korak i postavljanje tačaka prekida.

Učitavanje podataka

Za rešavanje opisanih problema potreban je način za mapiranje adrese izvršnog fajla na lokaciju u izvornom kodu i obrnuto. Obično oba ova mapiranja radi tabela linija (eng. line table), ali za izdvojene instrukcije ta dva smera su nezavisno implementirana na različite načine zato što su im potrebni različiti podaci a koji nisu svi dostupni u vreme kompilacije.

Interfejs za učitavanje i pristup informacijama za debagovanje u debageru LLDB je ostvaren kroz klasu SymbolFile. On pruža funkcije za parsiranje podataka iz različitih sekcija za debagovanje i njihovo dohvatanje u reprezentaciji nezavisnoj od formata u kome su napisane. Većina podataka se ne učitava odmah po pokretanju debagera već tek kada su ti podaci neophodni. Tako na primer dohvatanjem podataka za jedinicu kompilacije (eng. compile unit) kroz funkciju GetCompileUnitAtIndex se izvršava parsiranje te jedinice ukoliko već nije učitana. Za tabelu linija, odgovarajuća funkcija za učitavanje se intuitivno zove ParseLineTable, ali joj se pristupa pomoću funkcije GetLineTable klase CompileUnit. Kao i u ranijim poglavljima, podržani formati su implementirani kao priključci (eng. plug-ins). Svaki od njih implementira interfejs SymbolFile ili preciznije apstraktnu klasu SymbolFileCommon. U slučaju formata DWARF, implementacija se nalazi u klasi SymbolFileDWARF.

Podaci koji treba da budu učitani su skoro isti kao za tabelu linija, zbog toga se implementacija za učitavanje ugleda na učitavanje tabele linija. Uvedena je nova tabela linija specijalno za lokacije izdvojenih instrukcija. Za razliku od obične tabele, ova ne koristi specijalnu strukturu podataka već je u pitanju običan niz sortiran po lokaciji u izvornom kodu. Podaci se dobijaju obilaskom čitavog DWARF stabla

i parsiranjem atributa svih DW_TAG_LLVM_outlined_ref etiketa. Nakon učitavanja, nova tabela linija se predaje klasi CompileUnit preko koje može da joj se pristupi iz skoro celog koda. Bitniji metod pristupa je putem određivanja trenutnog konteksta izvršavanja. U poglavlju 3.3 je rečeno da se informacije o stanju programa dobijaju kroz instancu klase SymbolContext koja te podatke dobija iz informacija za debagovanje. Stanje programa podrazumeva jedinicu kompilacije, funkciju i lokacija u izvornom kodu. Jedan od načina za dobijanje tog konteksta je zadavanjem lokacije u izvornom kodu za koju treba odrediti taj kontekst. Bitno je napomenuti da lokacija dobijena iz konteksta ne mora da se poklapa sa prosleđenom lokacijom. Za kreiranje te instance zadužena je ponovo klasa CompileUnit, a funckija koja to obavlja je ResolveSymbolContext. Pored proveravanja najbliže lokacije iz tabele linija, dodata je i provera u izdvojenoj tabeli linija. Ukoliko iz obe tabele postoje takve lokacije, u kontekst se stavlja ona koja je bliža prosleđenoj. Ako samo jedna od tabela ima validan rezulat, koristiće se on. Sada svi koji koriste ovaj način dohvatanja konteksta mogu da dobiju informacije o izdvojenim instrukcijama. Upotreba ove izmene za rešenje konkretnog problema će biti prikazana kasnije.

Mapiranje u drugom smeru, sa adrese izdvojene instrukcije na lokaciju u izvornom kodu nije jedinstveno. Činjenica da je instrukcija izdvojena znači da se poziva na bar dva različita mesta u izvornom kodu. Zbog toga jednoj adresi će uvek odgovarati bar dve lokacije. Kako bi se dobila tačna lokacija potrebno je uzeti obzir i kontekst izvšavanja programa. Taj kontekst je predstavljen stek okvirom (eng. stack frame) funkcije koja je pozvala izdvojenu funkciju. Preciznije, predstavljen je adresom povratka (eng. return address) na funkciju kojoj odgovara taj stek okvir. Adresa povratka je adresa sledeće instrukcije koja će biti izvršena nakon povratka iz funkcije. Mapiranje u ovom smeru je smešteno u instanacama klase CallEdge. Neka su funkcije čvorovi usmerenog grafa, i neka grana između dva čvora postoji za svaki poziv funkcije u smeru od pozivaoca do pozvane funkcije. Može postojati više grana između dve funkcije ukoliko se ista funkcija poziva više puta. Klasom CallEdge predstavlja se jedna od tih grana. Ona je dopunjena da sadrži adrese i lokacije svih izdvojenih instrukcija prilikom tog poziva. Prethodno pomenuta klasa SymbolFile je zadužena za popunjavanje tih podataka kada su potrebni. Ta implementacija je smeštena u funkciji CollectCallEdges i zasniva se na parsiranju etikete poziva funkcije. Svim instancama klase CallEdge je moguće pristupiti iz kroz Function objekat pozivaoca, ili može da se pristupi konkretnoj instanci na osnovu adrese povratka.

Poslednji neophodan podatak koji je potrebno učitati je atribut DW_AT_LLVM_outlined. To je implementirano u okviru postojeće implementacije za učitavanje podataka o funkciji u klasi DWARFASTParserClang. Pristup informaciji da li je funkcija dobijena izdvajanjem koda je omogućen kroz metod IsOutlined dostupan nad objektima Function klase koja opisuje jednu funkciju iz koda koji se debaguje.

Ispisivanje ispravnih linija izvornog koda

Prilikom debagovanja korisnik može da kontroliše tok izvršavanja programa. On zadaje komande koje govore debageru koje delove koda da izvrši. Svaki put kada se kontrola vrati korisniku, debager ispiše mesto gde se program zaustavio (i možda nekoliko okolnih linija). Na osnovu toga korisnik saznaje informacije o trenutnom stanju programa i bira šta će sledeće da izvrši. U prisustvu dobrih debag lokacija to funkcioniše očekivano. Međutim u slučaju izvojenih instrukcija koje nemaju vrednost u tabeli linija, lokacija prikazana u debageru će biti netačna. Prikazana lokacija će pripadati prvoj ranijoj instrukciji koja ima lokaciju. Kako se izdvojene funkcije se dodaju na adresama iza svih korisničkih funkcija, prva ranija instrukcija može da pripada nekoj drugoj funkciji, ili čak može da joj odgovara lokacija koja označava kompajlerski generisan kôd. Korisnik ne dobija nikakvo obaveštenje o tome šta se desilo već samo može da vidi da je program napravio veliki skok na kraj fajla iako to nije slučaj.

Prvi izazov koji je potrebno rešiti kako bi imalo smisla rešavati bilo koji drugi problem je kako odrediti tačnu lokaciju u izvornom kodu kada se debager zaustavi u izdvojenoj funkciji. Bez toga iako se uspešno implementira bilo koji način zaustavljanja na izdvojene instrukcije, debager bi prikazivao netačne lokacije što samo otežava debagovanje. Trenutno jedini načini da se zastane na izdvojenoj instrukciji je da se program izvršava instrukciju po instrukciju ili da se postavi tačka prekida po adresi. Oba načina se mogu koristiti za proveru ispravnosti implementacije.

Ispisivanje statusne poruke, koja između ostalog uključuje i okolne redove gde je program zaustavljen radi funkcija GetStatus klase StackFrame. Taj deo koda je izmenjen na sledeći način. Prvo se proverava da li trenutni stek okvir pripada izdvojenoj funkciji. Podatak koji to opisuje je dostupan kroz metod IsOutlined klase Function, a ona se dobija na osnovu konteksta tog stek okvira. Ukoliko stek okvir ne pripada izdvojenoj funkciji, određivanje linije se svodi na postojeću implemetaciju. U suprotnom koristi se nova implementacija. U glavi 5.2 dodata je podrška za mapiranje adrese na liniju u izvornom kodu. Jedino što je potrebno je dodati

kontekst kako bi se odredila dobra CallEdge instanca za instrukciju. Funkcija već ima implementiran mehanizam za pronalaženje te instance na osnovu adrese povratka iz funkcije. Ta adresa se postavlja na vrh steka u trenutku poziva funkcije. Nit programa ima dostupnu listu stek okvira koji postoje u tom trenutku. Povratkom u roditeljski stek okvir lako je pronaći tu adresu. Konačna lokacija je dobijena iz CallEdge instance dobijene iz tog roditeljskog stek okvira pomoću metode Function::GetCallEdgeForReturnAddress sa pronađenom adresom povratka kao parametrom. Uz lokaciju, u status je dodata i poruka da je proces zaustavljen u izdvojenom kodu.

Izvršavanje korak po korak

Jedna od najkorišćenijih tehnika debagovanja je izvršavanje korak po korak. Ona omogućava korisniku da interaktivno prati i kontroliše izvršavanje programa. Između dva koraka korisnik može da pogleda vrednosti relevantnih promenljivih i priveri da li se one poklapaju sa očekivanim vrednostima. LLDB nudi nekoliko komandi za koračanje:

- step-over Izvršava sve naredbe do sledećeg reda u izvornom kodu preskačući pozvane funkcije
- step-into Izvršava sve naredbe do sledećeg reda u izvornom kodu pritom ulazeći u pozvane funkcije
- step-inst Izvršava jednu instrukciju izvršnog fajla

U postojećoj implementaciji jedino step-inst komandom je moguće stati na izdvojenu instrukciju. Druge komande, kako se oslanjaju na broj reda u izvornom kodu, će ih uvek preskočiti. Cilj ovog poglavlja je prepraviti i njih da rade u skladu sa korisnikovim očekivanjima.

Tokom sesije debagovanja, korsnik zadaje komande debageru kako bi kontrolisao tok izvršavanja programa. Celokupna logika o tome koliko program treba da se izvršava i kada treba da se zaustvi implementirana je pomoću planova niti (eng. thread plan). Više različitih planova može da bude aktivno u isto vreme, zbog čega se oni skladište u stek strukturi podataka. Svaka nit ima svoj stek planova i njemu se može pristupiti GetProcess().GetThreadPlans(GetID()) iz trenutne niti. Kada se program zaustavi zbog nekog događaja svi planovi za tu nit se proveravaju redom od vrha do dna steka. Traži se prvi plan koji može da objasni događaj koji je izazvao

zaustavljanje pozivanjem funkcije DoPlanExplainsStop svakog plana. Taj plan se ona upita da li treba da se vrati kontrola korisniku funkcijom ShouldStop. Ovde se ažurira logika ukoliko je potrebno da se program zaustavi na nekom sledećem mestu. Posle izvršavanja plana proverava se da li je on završio pozivom funkcije MischiefManaged. Ukoliko jeste, on i svi planovi iznad njega u steku su uklonjeni ukoliko prijave da više nisu relevantni. Uvek postoji bar jedan plan na steku. To je instanca ThreadPlanBase i on se aktivira kada ni jedan drugi plan ne objašnjava događaj kao na primer za tačke prekida napravljene od strane korisnika.

Postoji više implementacija planova koji imaju različite kriterijume za zaustavljanje. Fokus ovog poglavlja su implementacije ThreadPlanStepInRange i ThreadPlanStepOverRange koje se koriste redom za step-into i step-over komande. Oni dele zajedničku nadklasu ThreadPlanStepRange. Oba plana rade tako što postavljaju tačke prekida na sledeću intrukciju grananja sve dok program ne izađe iz opsega koji mu je zadat u vreme kreiranja. Taj opseg obuhvata sve instrukcije koje pipadaju istom redu i izvornom kodu. Nije moguće odmah postaviti tačku prekida direktno na konačnu lokaciju zbog mogućih grananja u programu. Razlika između planova je što step-into prilikom zaustavljanja na instrukciji poziva funkcije dodaje novi plan za ulazak u funkciju dok stop-over to ne radi.

Ideja rešenja je da se osim postojeće tačke prekida uvede još jedna koja se uvek postavlja na seldeću izdvojenu instrukciju. Nadklasa ThreadPlanStepRange je dopunjena funkcijama za postavljanje te nove tačke prekida koja se dobija na isti način kao u poglavlju 5.2. Posebno u slučaju step-over komande sledeća instrukcija grananja se traži uz bezuslovno preskakanje instrukcija poziva. Taj postupak je izmenjen dodavanjem uslova da pozvana funkcija nije nastala izdvajanjem koda. Ukoliko jeste, očekivano ponašanje je da debager ipak korača unutar te funkcije kako to odgovara izvornom kodu programa. U suprotnom poziv instrukcije se ignoriše kao i ranije.

Poslednje što je potrebno učiniti je izmeniti konkretne klase planova da dodavaju i proveravaju tačku prekida na izdvojenoj instrukciji. Razlikuju se dva slučaja u kojima je potrebno dodati ciljnu tačku prekida. Ulaskom u izdvojenu funkciju potrebno je postaviti sledeći cilj da bude prva izdvojena instrukcija sa lokacijom. Ukoliko je program već zautavljen usred izdvojene funkcije onda cilj postaje prva sledeća izdvojena instrukcija sa lokacijom u narednom redu. Prethodni slučajevi se lako razlikuju poređenjem odnosa između trenutnog stek okvira i okvira iz trenutka kreiranja plana. Kako bi se plan uopšte aktivirao prilikom dostizanja cilja, ta

provera je dodata u funkciju DoPlanExplainsStop. Obrada samog događaja se radi na početku funkcije ShouldStop gde se odmah vraća kontrola korisniku i plan se završava.

Postavljanje tačaka prekida

Tačka prekida (eng. breakpoint) je mesto u programu koje kada treba da se izvrši u debageru izaziva pauziranje izvršavanja i vraćanje kontrole korisniku. LLDB podržava nekoliko načina za postavljanje tačaka prekida:

- pomoću adrese u izvršnom fajlu Najjednostavniji vid postavljanja tačke prekida. Postavlja se tačno na prosleđenu adresu.
- pomoću imena funckije U izvornom kodu se pronalaze sve funkcije sa prosleđenim imenom i za svaku od njih dodaje se nova tačka prekida.
- pomoću imena fajla i reda Prosleđuje se naziv fajla i red u tom fajlu.
 Na osnovu informacija za debagovanje se tačka prekida postavlja na prvu instrukciju kojoj odgovara prosleđeni red ili prvi sledeći red ukoliko za traženi red ne postoje informacije.
- pomoću regularnog izraza Izvorni kôd se pretražuje za poklapanja sa regularnim izrazom i svako poklapanje dodaje novu tačku prekida.


Svi ovi načini se svode na postavljanje preko jedne ili više adresa.

Za potrebe razlikovanja, svakoj napravljenoj tački prekida dodeljuje se jedinstveni identifikator u formatu X.Y gde X označava identifikator grupe, a Y označava identifikator lokacije u toj grupi. Sve tačke prekida nastale istom komandom imaju istu vrednost X i različite vrednosti Y. Ne može da se desi da dve tačke prekida iz iste grupe imaju istu lokaciju. Ovaj identifikator se koristi za izmenu svojstava tačaka prekida i prikazuje se korisniku kada se program zaustavi usled dostizanja jedne od njih. Uspešnim izvršavanjem komande za postavljanje tačke prekida dobija se poruka nalik na onu u listingu 5.5.

```
* thread #1, name = 'test', stop reason = breakpoint 1.1
```

Slika 5.5: Primer poruke koju prikazuje debager LLDB prilikom postavljanja tačke prekida

Prva dva od prethodno opisanih načina rade očekivano za izdvojene instrukcije dok druga dva ne funkcionišu. Ono što izdvaja druga dva načina je što oni moraju da odrede adresu na osnovu lokacije u izvornom kodu. Tačno je da isti ovaj proces se koristi i za postavljanje tačke prekida po imanu funkcije ali kako izdvojeni kôd ne može da sadrži deklaraciju funkcije, na njega ne utiče dotični problem. Na sreću, potreban mehanizam je već ostvaren dodatnom tabelom linija za izdvojene instrukcije. Međutim i sa tim se javlja drugi problem. Sada prilikom debagovanja dolazi do neočekivanih zastajkivanja na tačke prekida koje korisnik nije postavio. Radi jednostavnosti, nastavak teksta se odnosi na slučaj zadavanja fajla i reda. Sve što će biti rečeno važi i za slučaj koji koristi regularne izraze. Problem je u tome što odgovarajuća adresa pripada izdvojenoj funkciji koja se poziva iz više mesta. Ilustracija ovog problema je prikazana na slici 5.6. Ukoliko korisnik postavi tačku



Slika 5.6: Vizuelni prikaz odnosa izdvojenog koda u izvornom kodu i izvršnom fajl

prekida bilo na red 17, do prekida će doći i prilikom izvršavanja linije 22 i obrnuto. Korisnik ne treba da bude svestan postojanja izdvojene funkcije jer on debaguje samo na osnovu izvornog koda. Za njega, očekivani ishod treba da bude da se program zautavlja samo na redu koji je on izabrao.

Rešenje problema nije moguće realizovati u vreme postavljanja tačke prekida, već se provera ispravnosti lokacije radi nakon izazivanja prekida ali pre povratka kontrole korisniku. Dok klasa Breakpoint poseduje sve podatke o grupi tačaka prekida koje su nastale istom komandom, informacije o svakoj pojedinačnoj instanci

se nalaze u okviru klase BreakpointLocation. Ona je dopunjena poljem koje predstavlja opcionu lokaciju u izvornom kodu koja odgovara toj adresi i poljem logičkog tipa koje obeležava da li je instrukcija izdvojena. Lokacija u izvornom kodu je neophodna samo za podršku izdvojenih instrukcija. Oba dodata polja dobijaju vrednost prilikom kreiranja tačke prekida na osnovu podataka iz tabela linija. Dolaskom na tačku prekida vrši se provera da li treba vratiti kontrolu korisniku kroz funkciju ShouldStop klase BreakpointLocation. U ovom trenutku je potrebno proveriti da li se lokacija poklapa sa lokacijom koja odgovara trenutnom stanju procesa. Način dobijanja trenutne lokacije je isti kao i u prethodna dva poglavlja, uz pomoć trenutne adrese i konteksta. Nigde u implementaciji se ne nalazi zavisnost na određeni način određivanja tačaka prekida tako da bi trebalo da funkcioniše Posebna pažnja je data da se ova provera radi pre bilo koje druge operacije koja može da izmeni stanje tačke prekida. Na primer pre uvećavanja brojača aktivacije tačke prekida koji korisnik može da korsiti za napredno debagovanje.

Glava 6

Rezultati

Modifikovanu verziju kompajlera i debagera je potrebno detaljno testirati u različitim mogućim situacijama kako bi se postarali da se prvenstveno ne smanjuje funckionalnost u odnosu na nemodifikovanu verziju, a zatim i da se zapravo unapređuje debagovanje izdvojenog koda. Kako je velika količina koda izmenjena, velike su šanse da je došlo do propusta u implementaciji koji nisu detektovani testiranjem na jednostavnim primerima u toku prvobitnog pisanja koda.

Projekat LLVM već uključuje veliki broj regresionih testova koji pokrivaju skoro svaku podržanu funkcionalnost. Ti testovi se pokreću koristeći pomocni alat lit (skraćeno za *LLVM Integrated Tester*) i sastoje se od fajlova koji sadrže kôd u nekom formatu i ugradjene direktive u vidu komantara. Direktive mogu da budu ili komande koje se pokreću za izvrsavanje testa ili direktive koje zadaju tvrdnje koje test proverava. Testovi se pokreću

Pokrenuti su svi testovi uključeni u LLVM projekat. Većina testova je uspešno izvršena bez problema. To je bilo i očekivano zato što veliki broj testova i ne radi sa uklječenim izdvajanjem koda. Mali deo testova je neuspešno izvršen zato što proverava specificne informacije za debagovanje koje su izmenjene modifikovanim kompajlerom. U tim situacijama, odgovarajući testovi su izmenjeni tako da očekuju pojavljivanje novih etiketa i atributa. Poslednji, poseban slučaj je činio test koji sadrži istovremeno izdvojen i umetnut kôd. Ova situacija nije bila predviđena prilikom pisanja implementacije. Dotični test je prevremeno zaustavljao zbog neispunjene tvrdnje da poziv funkcije koja moze da bude umetnuta unutar funkcije koja ima inforamcije za debagovanje mora da ima lokaciju. Za taj slučaj je dodata posebna podrška. Za pozive koji ispunjavaju opisani uslov se postavlja veštačka debag lokacija.

Ispravkom poslednjeg testa, nije uočeno više problema i svi testovi su se uspešno izršavali. Sledeće je potrebno isprobati da li implementacija uspešno rešava probleme koje je namenjena da reši. Demonstracija će biti prikazana na istom primeru prestavljenim ranije u listingu 1. Ponašanje debagera na izdvojenom kodu pre modifikacija je opisano u glavi 4.2.

Kompilacijom sa modifikovanim kompajlerom i proverom informacija za debagovanje izvršnog fajla se može se primetiti da su nove etikete generisane na mestima poziva funkcija i da se adrese poklapaju sa adresama instrukcija u izdvojenoj funkciji. Pokretanjem debagera na generisanom fajlu i koračanjem po programu dobija se ispis prikazan u slici 6.1. Ukoliko se ovaj ispis uporedi sa ispisom pre modifikacija primećuje se da se program zaustavlja na 3 od 4 izdvojene instrukcije što prethodno nije bio slučaj, Takođe, svaki put kad se zastane ispisuje se poruka koja govori da se proces nalazi u izdvojenoj funkciji. Četvrta naredba, c1--;, ne izaziva prekid izvršavanja programa. Istraživanjem je otkriveno da se odgovarajuća instrukcija koja je u početku bila instrukcija sabiranja sa -1, u toku izbora instrukcija zamenila sa instrukcijom dekrementiranja za 1. Zbog te zamene izgubljen je outline_id koji je ta instrukcija originalno imala, stoga nije bilo moguće pronaći adresu te instrukcije prilikom emitovanja asemblerskog koda. Dakle, još uvek postoji prostor za poboljšanje implementacije.

Još jedna implementirana funkcionalnost koju treba proveriti je postavljanje tacaka prekida. U prethodnom primeru je izgledalo kao da se uspesno postavila tacka prekida na liniji 11 koja je izdvojena. Ono sto se zapravo desilo je da se tacka postavila na instrukciju poziva izdvojene funkcije koja je dobila lokaciju prve izdvojene instrukcije. Tek sledecim korakom se zapravo doslo do izdvojene instrukcije. Umesto te naredbe na redu 11, tacka ce biti postavljena na red 13 kako bi se izbegla prethodna situacija. Ispis debagera je prikazan na slici 6.2. Komanda za postavljanje tacke prekida je uspesno odredila adresu koja odgovara zadatoj liniji i pokretanjem programa, proces je zaustavljen na toja adresi.

Novi regresioni testovi su dodati za kompajler i debager po ugledu na prethodni primer. Kompajleru se testira uspešno generisanje informacija za debagovanje u svakom koraku kompilacije. Debager testovi pokreću debager nad programom sa izdvojenim kodom i proveravaju ispravnost lokacije, da li se program zaustvio na očekivanim mestima i da li je uspešno postavljena tačka prekida.

```
$ 11db outline
(lldb) b 11
(lldb) r
    9
                int y = 1;
    10
 -> 11
                int c1 = x + y;
    12
                c1--;
    13
                global += 2;
(lldb) n
    9
                int y = 1;
    10
 -> 11
                int c1 = x + y;
    12
                c1--;
    13
                global += 2;
Note: this function is outlined.
(lldb) n
                int c1 = x + y;
    11
    12
                c1--;
 -> 13
                global += 2;
    14
                foo(c1, global);
Note: this function is outlined.
(lldb) n
                c1--;
    12
                global += 2;
    13
 -> 14
                foo(c1, global);
    15
                int c2 = x + y;
Note: this function is outlined.
```

Slika 6.1: Koračanje po izdvojenom kodu sa izmenjenim debagerom

```
$ 11db outline
(lldb) b 13
Breakpoint 1: where = outline`outlined_ir_func_0 + 11 at outline.c,
\hookrightarrow address = 0x0000555555551a0
(lldb) r
    10
    11
                        int c1 = x + y;
    12
                        c1--;
                        global += 2;
 -> 13
    14
                        foo(c1, global);
    15
    16
                int c2 = x + y;
Note: this function is outlined.
```

Slika 6.2: Postavljanje tačke prekida na izdvojenu naredbu sa izmenjenim debagerom

Glava 7

Zaključak

U okviru ovog rada su opisani proces kompilacije sa akcentom na optimizacijama koda i postupak otklanjanja grešaka u softveru pomoću debagera. Detaljno je
objašnjena uloga informacija za debagovanje i problem održavanja tih informacija
prilikom izvršavanja kompajlerskih optimizacija. Za potrebe kompilacije i debagovanja korišćeni su alati infrastrukture LLVM, konkretno kompajler LLVM i debager
LLDB. Glavni predmet rada je optimizacija izdvajanja koda koja štedi memoriju
programa tako što pomera ponovljene delove koda u funkciju i uklanja duplikate. To
smanjenje krajnjeg koda predstavlja problem očuvanju informacija za debagovanje
i dovodi do problema prilikom upotrebe debagera.

Doprinos ove teze je poboljšanje očuvanja informacija za debagovanje prilikom optimizacije izdvajanja koda u okviru kompajlera LLVM. One su sačuvane prilikom primene optimizacije, prenete kroz sve faze kompilacije i upisane u sekciju za debagovanje izvršnog fajla. Na osnovu toga poboljšan je i debager LLDB da iskoristi te informacije kako bi se ostvarilo bolje iskustvo debagovanja. Dodata je podrška za ispisivanje ispravnih lokacija iz izvornog koda, koračanje i postavljanje tačaka prekida na izdvojenom kodu.

Postoji nekoliko pravaca daljeg razvoja. Predloženo rešenje je moguće implementirati i u drugim kompajlerima i debagerima kao što su *GCC* i *GDB*. Pored toga, moguća su poboljšanja ove implementacije u okviru infrastrukture LLVM. Trenutno postoji podrška za čuvanje debag lokacija samo iz prolaza IROutliner. Kako se već svakako te informacije spuštaju do mašinski zavisnog međukoda na putu do izvršnog fajla, moguće je dodati podršku i za prolaz MachineOutliner. Pored toga, trenutna implementacija funkcioniše samo za implementaciju SelectionDAG za izbor instrukcija. Iako je to dovoljno za sada, u budućnosti kada implementacija

GlobalIsel bude prešla u širu upotrebu biće potrebno podržati i tu implementaciju. Na kraju, jedna posledica nastala opisanim izmenama je što pregled stek okvira dok je proces zaustavljen u izdvojenoj funkciji prikazuje stek okvir i te izdvojene funkcije. Kako ona ne postoji u izvornom kodu, korisniku ne treba da bude prikazana prilikom debagovanja. Suprotna stvar se dešava kada je proces zaustavljen u umetnutom kodu, gde se konstruiše veštački stek okvir koji ne postoji u toku izvršavanja, ali korisnik očekuje da bude prisutan.

Bibliografija

- [1] Amy Brown and Greg Wilson. The Architecture of Open Source Applications: Elegance, Evolution, and a Few Fearless Hacks. The Achrictecture of Open Source Applications. Creative Commons, 2011.
- [2] K.D. Cooper and L. Torczon. Engineering a Compiler. Elsevier Science, 2022.
- [3] DWARF Debugging Information Format Committee. DWARF Debugging Information Format Version 5.
- [4] Michael J. Eager. Introduction to the dwarf debugging format, 2012.
- [5] The LLVM Foundation. The lldb debugger. on-line at: https://lldb.llvm.org/.
- [6] The LLVM Foundation. The llvm compiler infrastructure. on-line at: https://llvm.org/.
- [7] The LLVM Foundation. Llvm language reference manual. on-line at: https://llvm.org/docs/LangRef.html.
- [8] The LLVM Foundation. Machine ir (mir) format reference manual. on-line at: https://www.llvm.org/docs/MIRLangRef.html.
- [9] Dick Grune, Kees van Reeuwijk, Henri E. Bal, Ceriel J.H. Jacobs, and Koen Langendoen. *Modern Compiler Design*. Springer Publishing Company, Incorporated, 2nd edition, 2012.
- [10] Jakub Jelinek. Representation of call sites in the debugging information, 2010.
- [11] Jakub Jelinek. Tracking of values passed as arguments to functions in debug information, 2010.

- [12] Andrew Litteken. Framework for finding and using similarity at the ir level, 2020.
- [13] mayur Pandey and S. Sarda. LLVM cookbook: over 80 engaging recipes that will help you build a compiler frontend, optimizer, and code generator using LLVM. PACKT, 2017.
- [14] Jessica Paquette. Interprocedural mir-level outlining pass, 2016.
- [15] S. Sarda and M. Pandey. *LLVM Essentials*. Community experience distilled. Packt Publishing, 2015.
- [16] Anastasia Stulova and Sven van Haastregt. An overview of clang. Technical report, Arm, Cambridge, UK, 2019.
- [17] E. Ukkonen. On-line Construction of Suffix-trees. Series of publications / University of Helsinki, Department of Computer Science. A. University of Helsinki, Department of Computer Science, 1993.
- [18] Peng Zhao and José Nelson Amaral. Function outlining and partial inlining. 17th International Symposium on Computer Architecture and High Performance Computing (SBAC-PAD'05), pages 101–108, 2005.

Biografija autora

Vladimir Vuksanović je rođen 2. januara 1999. godine u Užicu. Tamo je završio osnovnu školu i prirodno-matematički smer Užičke gimnazije. Posle toga je upisao informatički smer na Matematičkom fakultetu 2017. godine. Osnovne studije je završio za 4 godine sa prosekom 9,82. Nagrađen je kao jedan od najuspešnijih studenata generacije od strane katedre za računarstvo i informatiku i dobitnik je nagrade "Nedeljko Parezanović". Iste godine je upisao master studije na Matematičkom fakultetu takođe na smeru informatika. Pred kraj studija je radio praksu u kompaniji Sirmija posle čega se tamo zaposlio kao softverski inženjer. Tamo radi na sistemskom softveru, primarno na projektima vezanim za infrastrukturu LLVM.